When Classical Optimization Meets Modern Foundation Models:
New Algorithms, Theory, and Insights
Mingyi Hong
Department of Electrical and Computer Engineering,
University of Minnesota, Minneapolis
UNIVERSITY OF MINNESOTA
Driven to Discover℠
July 1, 2026

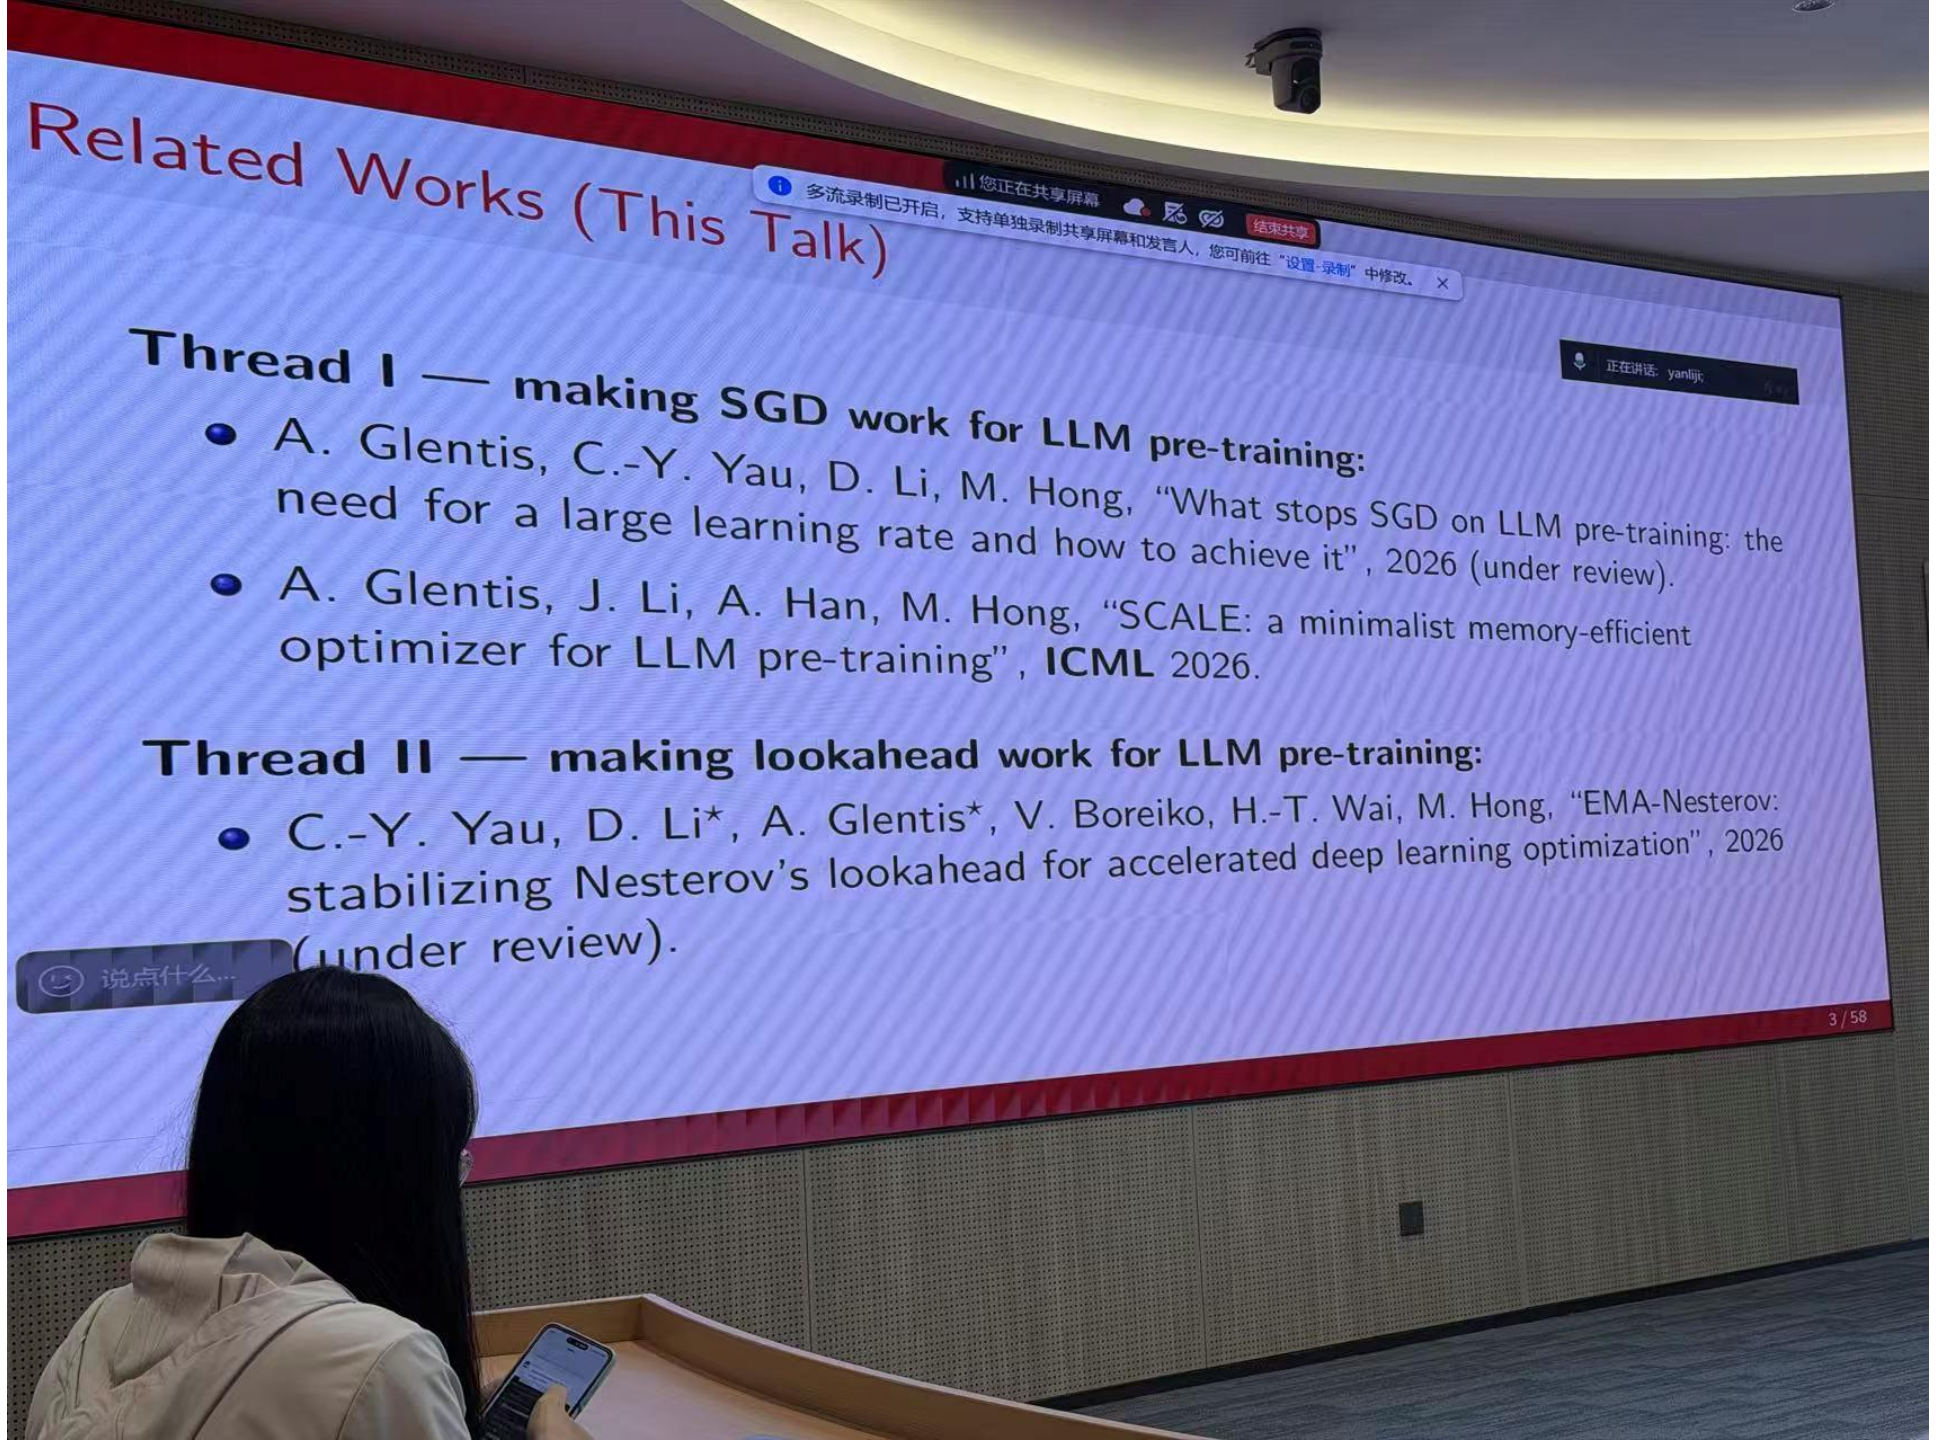
Related Works (This Talk)
多流录制已开启，支持单独录制共享屏幕和发言人，您可前往“设置-录制”中修改。
您正在共享屏幕
结束共享
正在讲话：yanlijic
Thread I — making SGD work for LLM pre-training:
A. Glentis, C.-Y. Yau, D. Li, M. Hong, “What stops SGD on LLM pre-training: the need for a large learning rate and how to achieve it”, 2026 (under review).
A. Glentis, J. Li, A. Han, M. Hong, “SCALE: a minimalist memory-efficient optimizer for LLM pre-training”, ICML 2026.
Thread II — making lookahead work for LLM pre-training:
C.-Y. Yau, D. Li*, A. Glentis*, V. Boreiko, H.-T. Wai, M. Hong, “EMA-Nesterov: stabilizing Nesterov’s lookahead for accelerated deep learning optimization”, 2026 (under review).
说点什么...
3 / 58

会议详情 02:19 yanliji正在共享屏幕
演讲者布局 设置
元宝纪要
正在讲话:
会议概览
本次会议讨论了经典优化算法在大模型训练中的应用价值，特别是Nesterov动量的稳定性问题。
小结
元宝会议助手 刚刚
hi，我是你的元宝会议助手，我正在帮你实时记录会议纪要，请安心开会！
会议结束后，你可以在会议详情页查看完整记录。
元宝会议助手 刚刚
yanliji 指出Nesterov动量在深度学习训练中表现不稳定，并计划后续剖析原因及改进方案，可见当前主流优化器在该技术路线上仍存在明显短板。
随后他澄清Nesterov动量是经典的确定性优化加速方法，并强调现有Sora算法并未真正采用该技术，这直接戳破了部分算法在理论应用上的“伪创新”假象。
我正在听，2分钟后生成总结... 立即总结

This Talk

- **Part I. Making SGD work for LLM pre-training**
  - Why does SGD so much worse compared with Adam?
  - We identify two structural irregularities in the LLM gradients
  - A simple fix, SGD-LL (SGD with Large LR via clipping) closes the gap to $\sim 3.5\%$.
  - Distill the insight into SCALE: a column-normalized, last-layer-momentum optimizer that are competitive with Adam while at ~ 35–45% in memory usage.
- **Part II. Making Nesterov's acceleration work**
  - Why does naive Nesterov lookahead not stable on deep-net?
  - EMA-Nesterov: an EMA-stabilized lookahead direction.
  - Accelerated convex rates preserved;
  - Consistent gains on a wide range of optimizers, Adam/SOAP/Muon up to LLaMA 1B.
- **Closing.** Exploit the structure of the models, and classical optimization still can contribute significantly to modern optimizer design.

批注
说点什么...
选择音频 开启视频 共享屏幕 成员(22) 邀请 聊天 录制 元宝纪要 应用 离开会议
元宝会议助手
洞察讨论观点，总结纪要及待办

What Stops SGD on LLM Pre-Training?

Plain (momentum) SGD fails in standard LLM pre-training. But why?

- **Many prior explanations.** Ill-conditioned sharpness *(Pan & Li '23)*; heavy-tailed class imbalance *(Kunstner+ NeurIPS'24)*; Hessian block heterogeneity *(Zhang+ NeurIPS'24)*; . . .
- **Recent observation.** At very small batch sizes, SGD matches Adam *(Marek+ '25, Sreckovic+ '25)*.
- **Gap:** In the broader pre-training setup, what SGD is doing during training and why it can't keep up remain much less explored.

Our Observation

SGD only explores a small neighborhood around the initialization; Adam can leverage large effective learning rates to explore larger neighborhood.

正在讲话: yanliji;

会议概览

本次会议旨在探讨SGD和Nesterov加速等经典优化算法在现代大语言模型训练中的适用性，并提出了相应的改进方案。

小结

印象，为后续研究定下基调。

随后，他梳理了“诊断问题-算法修复-理论验证-实验证明”的研究路径，并顺势切入第一部分，着手解决SGD的落地应用问题，可见其研究逻辑极为严密，从理论诊断到实验验证形成了完整闭环。

元宝会议助手 刚刚

yanliji 指出SGD表现远逊于Adam，经分析梯度异常并引入大学习率裁剪后，性能差距大幅缩小至3.5%，这说明SGD的劣势并非无解，通过针对性修复即可大幅缩小与主流方法的差距。

基于此，他开发出低内存消耗的SCALE算法，并顺势将研究推进至第二部分，着手优化Nesterov加速方法，可见其研究逻辑十分清晰，先修复基础算法，再将其提炼为轻量化方案并拓展应用。

元宝会议助手 刚刚

yanliji 指出该稳定化算法具备理论支撑，且能广泛适配Adam等主流优化器，在nano gpt等基准测试中表现优异，这表明该算法不仅具备理论高度，更在主流模型上通过了实战检验，通用性极强。

随后，yanliji 切入第一部分，详细拆解了动量SGD的更新机制，明确了权重更新公式及动量项的指数移动平均计算方式，从宏观算法效果直接落地到微观数学公式，教学逻辑由浅入深，旨在夯实理论基础。

我正在听，2分钟后生成总结... 立即总结

元宝会议助手
洞察讨论观点，总结纪要及待办

Training Dynamics: SGD vs. Adam

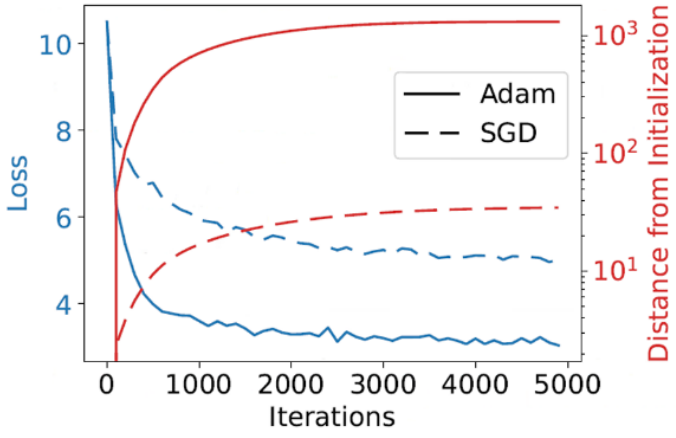

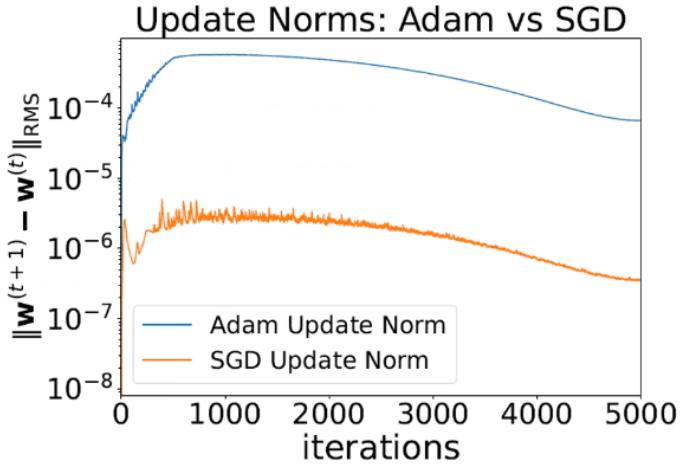

LLaMA-130M, token batch size 0.5M. (Left) loss + distance from initialization. (Right) per-layer RMS update norm.

- **Left.** Effective solution space of SGD is $\sim 50\times$ smaller than Adam's; even though tuned SGD LR (0.5) is $\sim 166\times$ Adam's (3×10^{-3}).
- **Right.** Adam's per-layer update norm stays $\sim 100\times$ larger than SGD's.

Question. Why? $\Rightarrow$ Effective learning rates.

会议详情 06:13
yanliji正在共享屏幕
演讲者布局 设置
正在讲话: yanliji;
元宝纪要
会议概览
本次会议旨在探讨SGD和Nesterov加速等经典优化算法在现代大语言模型训练中的适用性，并提出了相应的改进方案。
小结
劣势并非无解，通过针对性修复即可大幅缩小与主流方法的差距。
基于此，他开发出低内存消耗的SCALE算法，并顺势将研究推进至第二部分，着手优化Nesterov加速方法，可见其研究逻辑十分清晰，先修复基础算法，再将其提炼为轻量化方案并拓展应用。
元宝会议助手 刚刚
yanliji 指出该稳定化算法具备理论支撑，且能广泛适配Adam等主流优化器，在nano gpt等基准测试中表现优异，这表明该算法不仅具备理论高度，更在主流模型上通过了实战检验，通用性极强。
随后，yanliji 切入第一部分，详细拆解了动量SGD的更新机制，明确了权重更新公式及动量项的指数移动平均计算方式，从宏观算法效果直接落地到微观数学公式，教学逻辑由浅入深，旨在夯实理论基础。
元宝会议助手 刚刚
yanliji 进一步拆解了Adam算法，指出其在动量基础上引入了二阶动量Vt，通过梯度平方的逐元素运算来动态调整更新步长，这其实就是Adam能自适应调整学习率的核心机制。
随后，yanliji 指出无论是普通SGD还是带动量的SGD，在标准大语言模型训练中均表现不佳，且这一现象已得到广泛验证，可见基础优化器在LLM训练上存在明显瓶颈，这也是引入Adam等高级算法的直接动因。
我正在听，2分钟后生成总结... 立即总结
元宝会议助手
洞察讨论观点，总结纪要及待办
批注
说点什么...
选择音频 开启视频 共享屏幕 成员(24) 邀请 聊天 录制 元宝纪要 应用 离开会议

Effective Learning Rates (LRs): Adam vs. SGD

Nominal LRs:

Adam: $\eta_{\text{Adam}} = 3 \times 10^{-3}$

SGD: $\eta_{\text{SGD}} = 5 \times 10^{-1}$

(both tuned; SGD diverges at higher LR)

Per-step updates:

$$\text{Adam: } \theta^{t+1} \leftarrow \theta^t - \frac{\eta_{\text{Adam}}}{\sqrt{v^t}+\epsilon} m^t$$

$$\text{SGD: } \theta^{t+1} \leftarrow \theta^t - \eta_{\text{SGD}}\, m^t$$

Observation. Adam's effective LRs are 2–4 orders larger than SGD's.

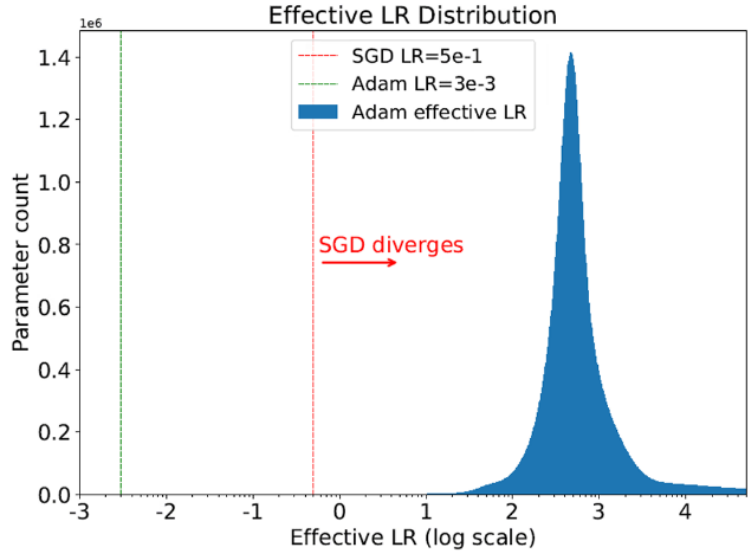

Per-layer effective learning rate distribution for Adam.

Q1: Why such a large effective LR even needed? **Q2:** Why we cannot increase SGD's LR?

会议详情 08:01 yanliji正在共享屏幕
演讲者布局 设置
元宝纪要
正在讲话:
会议概览
本次会议旨在探讨SGD及Nesterov加速器在基础模型训练中的有效性，并通过案例研究分析其性能差距及优化方案。
小结
随后，yanliji 切入第一部分，详细拆解了动量SGD的更新机制，明确了权重更新公式及动量项的指数移动平均计算方式，从宏观算法效果直接落地到微观数学公式，教学逻辑由浅入深，旨在夯实理论基础。
元宝会议助手 刚刚
yanliji 进一步拆解了Adam算法，指出其在动量基础上引入了二阶动量Vt，通过梯度平方的逐元素运算来动态调整更新步长，这其实就是Adam能自适应调整学习率的核心机制。
随后，yanliji 指出无论是普通SGD还是带动量的SGD，在标准大语言模型训练中均表现不佳，且这一现象已得到广泛验证，可见基础优化器在LLM训练上存在明显瓶颈，这也是引入Adam等高级算法的直接动因。
元宝会议助手 刚刚
yanliji 指出SGD在极小批量下虽能匹配Adam，但在主流预训练中表现仍远逊于Adam，这表明小批量下的性能对齐存在局限性，无法复用到实际的大模型预训练场景。
为此，他提出核心观察：SGD仅能探索初始点附近的小邻域，而Adam凭借大有效学习率能探索更大范围，一语道破两者性能差异的本质，即探索能力的悬殊。
随后，他结合图表数据佐证，Adam的Loss下降极快，而SGD不仅收敛慢，且距离初始点的偏移量极小，用直观的数据印证了前文关于SGD“困在原地”的结论。
我正在听，2分钟后生成总结... 立即总结
元宝会议助手
洞察讨论观点，总结纪要及待办
批注
说点什么...
选择音频 开启视频 共享屏幕 成员(24) 邀请 聊天 录制 元宝纪要 应用 离开会议

Why Large LR is Needed: Weight-to-Gradient Norm Ratio

Observation. In LLM pre-training the stochastic gradient (and momentum) are tiny compared to the weights; large effective LR is needed just to move; the weight/SG ratio gets worse with batch size.

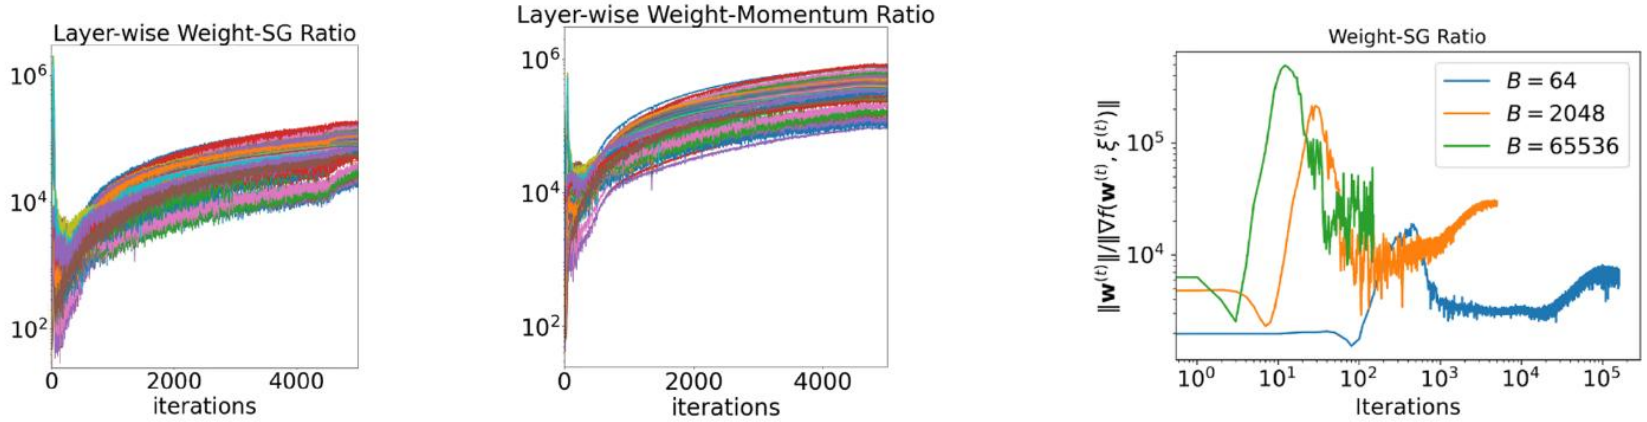

Dynamics of $\|w_\ell^{(t)}\|_F / \|\nabla f(w^{(t)}; \xi^{(t)})_\ell\|_F$ and $\|w_\ell^{(t)}\|_F / \|m_\ell^{(t)}\|_F$ per layer during pre-training.

- Adam's preconditioner $1/(\sqrt{v^t} + \epsilon)$ inflates per-coordinate steps significantly.
- SGD lacks this knob; needs a large global LR, but can't get there without diverging.

元宝纪要
正在讲话: yanliji;
会议概览
本次会议旨在探讨SGD及Nesterov加速器在基础模型训练中的有效性，并通过案例研究分析其性能差距及优化方案。
小结
随后，yanliji 指出无论是普通SGD还是带动量的SGD，在标准大语言模型训练中均表现不佳，且这一现象已得到广泛验证，可见基础优化器在LLM训练上存在明显瓶颈，这也是引入Adam等高级算法的直接动因。
元宝会议助手 刚刚
yanliji 指出SGD在极小批量下虽能匹配Adam，但在主流预训练中表现仍远逊于Adam，这表明小批量下的性能对齐存在局限性，无法复用到实际的大模型预训练场景。
为此，他提出核心观察：SGD仅能探索初始点附近的小邻域，而Adam凭借大有效学习率能探索更大范围，一语道破两者性能差异的本质，即探索能力的悬殊。
随后，他结合图表数据佐证，Adam的Loss下降极快，而SGD不仅收敛慢，且距离初始点的偏移量极小，用直观的数据印证了前文关于SGD“困在原地”的结论。
元宝会议助手 刚刚
yanliji 展示了更新范数对比图，指出Adam的单步更新幅度远超SGD，进而抛出核心疑问：为何Adam在极小学习率下仍能实现大步长探索？这直接点破了常规认知的盲区，将讨论焦点从表象差异引向底层机制。
随后他对比了两者的学习率设定，强调SGD已逼近发散极限，而Adam虽采用极小的固定学习率却表现优异，进一步凸显了两者机制的本质差异。可见Adam的优异表现并非单纯依赖学习率，而是其自适应机制在起作用。
我正在听，2分钟后生成总结... 立即总结
元宝会议助手
洞察讨论观点，总结纪要及待办

Why is the Gradient So Small? A Decomposition

Q1. Why is the gradient / momentum tiny in pre-training?

Theorem (Gradient Norm Upper Bound with Partition)

Given any partition $\mathcal{P}$ of token classes, the output-layer gradient norm satisfies

$$\|G\|_F \leq \mathcal{O}(1/\sqrt{B}) + \varepsilon_{\mathcal{P}},$$

where B is batch size and $\varepsilon_{\mathcal{P}}$ is a collective bound of token contributions dependent on how we partition the token classes into frequent and infrequent ones.

- Large batch $B \Rightarrow \mathcal{O}(1/\sqrt{B})$ covariance term is small.
- Choosing proper partition $\mathcal{P} \Rightarrow \varepsilon_{\mathcal{P}}$ is small.

A1. Gradient norm is structurally tiny, so large effective LR is unavoidable.

批注

正在讲话:

会议概览

本次会议旨在探讨SGD和Nesterov加速器在基础模型训练中的有效性，并通过案例研究分析其性能差距及优化方案。

小结

yanliji 展示了更新范数对比图，指出Adam的单步更新幅度远超SGD，进而抛出核心疑问：为何Adam在极小学习率下仍能实现大步长探索？这直接点破了常规认知的盲区，将讨论焦点从表象差异引向底层机制。

随后他对比了两者的学习率设定，强调SGD已逼近发散极限，而Adam虽采用极小的固定学习率却表现优异，进一步凸显了两者机制的本质差异。可见Adam的优异表现并非单纯依赖学习率，而是其自适应机制在起作用。

元宝会议助手 刚刚

yanliji 指出SGD调参后步长反而变差，核心在于Adam的有效学习率受分母根号项影响呈动态分布，从而大幅提升了步长，这解释了为何Adam名义学习率虽小，实际步长却能碾压SGD。

随后，yanliji 抛出新问题，探讨为何Adam需要如此大的有效学习率，而SGD却只需很小的学习率，顺势将讨论焦点从现象对比引向了底层原理的剖析。

元宝会议助手 刚刚

yanliji 引入“权重与梯度范数比值”指标，指出该比值极大，意味着梯度尺寸极小，这直接点破了Adam需要大学习率的底层逻辑，本质是为了弥补梯度过小带来的更新乏力。

随后，他结合图表展示各网络层在训练中该比值的变化趋势，并补充了除以动量后的对比情况，可见随着训练推进，梯度相对权重愈发微小，这种动态变化正是调参时必须考量的核心变量。

我正在听，2分钟后生成总结... 立即总结

元宝会议助手
洞察讨论观点，总结纪要及待办

Why SGD Diverges at Large LR: Gradient Irregularities

Q2. If we just crank up SGD's LR, why does it diverge?

A2. Two structural irregularities of the LLM stochastic gradient:

(Type I) Layer-wise SG spikes.

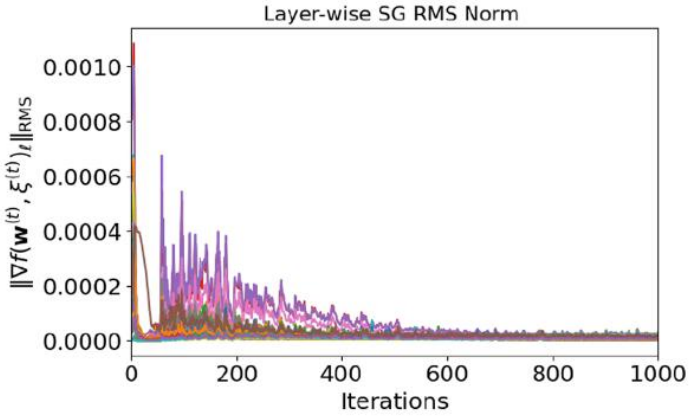

Layer-wise $\|\nabla f(w^{(t)}; \xi^{(t)})_\ell\|_{\mathrm{RMS}}$.

(Type II) Output-layer per-token-class imbalance.

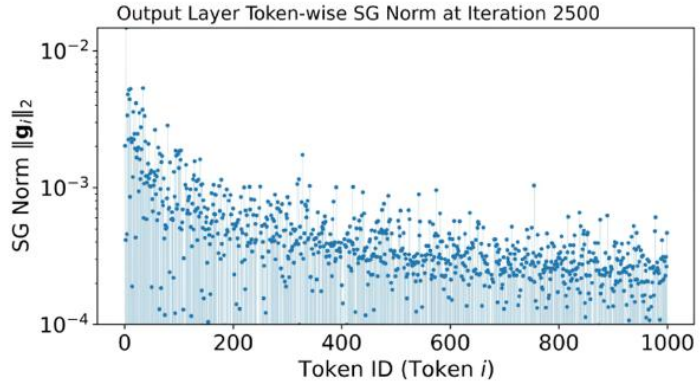

Per-token-class column grad-norm $\|g_i\|_2$; lower token IDs dominate.

A small set of "loud" layers / tokens blows up at high LR before training can progress.

会议详情 12:39 yanliji正在共享屏幕
演讲者布局 设置
元宝纪要
正在讲话: yanliji;
会议概览
本次会议讨论了SGD和Nesterov加速器在大语言模型训练中的表现，并分析了其性能差距的原因，旨在通过理论分析和算法改进使其重新变得有用。
随后，yanliji 抛出新问题，探讨为何Adam需要如此大的有效学习率，而SGD却只需很小的学习率，顺势将讨论焦点从现象对比引向了底层原理的剖析。
元宝会议助手 刚刚
yanliji 引入"权重与梯度范数比值"指标，指出该比值极大，意味着梯度尺寸极小，这直接点破了Adam需要大学习率的底层逻辑，本质是为了弥补梯度过小带来的更新乏力。
随后，他结合图表展示各网络层在训练中该比值的变化趋势，并补充了除以动量后的对比情况，可见随着训练推进，梯度相对权重愈发微小，这种动态变化正是调参时必须考量的核心变量。
元宝会议助手 刚刚
yanliji 指出增大批次大小会加剧梯度与权重的量级差异，进而推导出必须使用大学习率才能推动训练进度，这直接点透了预训练阶段的学习率瓶颈，梯度太小，不用大步子根本走不动。
随后，yanliji 解释Adam优化器通过预调节器显著放大了有效学习率，从而弥补了SGD的缺陷，相当于给SGD装了个"加速器"，用算法手段强行打破了梯度微小的限制。
基于上述推导，yanliji 最终明确预训练阶段梯度与动量极小的核心原因在于其极小的范数结构，至此，他完成了对第一个核心疑问的闭环解答，将现象归因到了底层数学结构上。
我正在听，2分钟后生成总结... 立即总结
元宝会议助手
洞察讨论观点，总结纪要及待办
批注
说点什么...
选择音频 开启视频 共享屏幕 成员(24) 邀请 聊天 录制 元宝纪要 应用 离开会议

Output-Layer is Special

The output (lm_head) layer is special. It maps the last hidden state to vocabulary logits; each column of G corresponds to one of $|V|$ tokens.

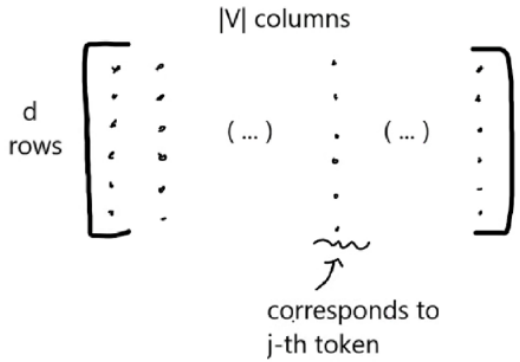

- Each column represents features for one token class
- The dimension of the matrix is about 32k x d (d depends on the model size, 2k for 1B model)
- Per-token-class grad norms span 3–4 orders of magnitude, and frequent tokens dominate.

Sketch: last-layer grad matrix; each column = one token class.

会议详情 14:29
yanliji正在共享屏幕
演讲者布局 设置
正在讲话: yanliji;
元宝纪要
会议概览
本次会议旨在探讨SGD及Nesterov加速器在基础模型训练中的有效性，并分析其性能差距的原因及解决方案。
小结
随后，yanliji 解释Adam优化器通过预调节器显著放大了有效学习率，从而弥补了SGD的缺陷，相当于给SGD装了个“加速器”，用算法手段强行打破了梯度微小的限制。
基于上述推导，yanliji 最终明确预训练阶段梯度与动量极小的核心原因在于其极小的范数结构，至此，他完成了对第一个核心疑问的闭环解答，将现象归因到了底层数学结构上。
元宝会议助手 刚刚
yanliji 提出定理，指出Transformer的梯度范数受两项约束，其中首项与批大小平方根成反比，解释了批大小越大梯度越小的现象，这从理论层面印证了前文关于大批次导致梯度缩小的观察。
针对定理中的另一项常数，他坦言其难以解释并建议查阅论文，进而总结该定理旨在解释常规训练中梯度为何极小，遇到难以展开的细节果断略过，直接抛出论文，有效保障了授课节奏。
元宝会议助手 刚刚
yanliji 顺势抛出第二个核心问题，即为何不能简单粗暴地调大学习率来解决问题，这直击了理论推导与实际落地的矛盾点。
针对该疑问，他揭示了语言模型训练存在梯度不规则现象，指出各层梯度范数波动极大，若盲目使用大学习率极易导致特定层梯度爆炸，可见模型各层对大学习率的耐受度参差不齐，强行拉满极易引发训练崩盘。
我正在听，2分钟后生成总结... 立即总结
元宝会议助手
洞察讨论观点，总结纪要及待办
批注
说点什么...
选择音频 开启视频 共享屏幕 成员(23) 邀请 聊天 录制 元宝纪要 应用
显示隐藏的图标

Enabling High-LR SGD via Clipping: SGD-LL

SGD-LL = SGD with **L**arge effective **L**earning rate, enabled by structure-aware clipping.

Clipping operator: $\mathrm{clip}_{r,\|\cdot\|}(x) := \min\left\{1, \frac{r}{\|x\|}\right\} x.$

- **Resolve Type I:** layer-wise RMS clipping for intermediate layers,

$$w_\ell^{(t+1)} = w_\ell^{(t)} - \mathrm{clip}_{\tau,\|\cdot\|_{\mathrm{RMS}}}(\eta_t\, m_\ell^{(t)}), \qquad \ell = 1, \ldots, L-1.$$

- **Resolve Type II:** per-token-class ℓ_2 clipping on top of layer clipping for output layer,

$$w_L^{(t+1)} = w_L^{(t)} - \mathrm{clip}_{\tau,\|\cdot\|_{\mathrm{RMS}}}(\eta_t\, \widetilde{m}_L^{(t)}), \quad \widetilde{m}_{L,i}^{(t)} = \mathrm{clip}_{\delta,\|\cdot\|_2}(m_{L,i}^{(t)}), \quad i = 1, \ldots, V.$$

$\Rightarrow$ allows tuned SGD LR up to $\eta \in [100, 300]$ (vs. vanilla SGD diverging at $\eta > 0.5$).

批注

正在讲话: yanliji;

会议概览

本次会议旨在探讨SGD和Nesterov加速器在大语言模型训练中的有效性，并分析其表现不佳的原因及相应的解决方案。

小结

yanliji 提出定理，指出Transformer的梯度范数受网络约束，其中首项与批大小平方根成反比，解释了批大小越大梯度越小的现象，这从理论层面印证了前文关于大批次导致梯度缩小的观察。

针对定理中的另一项常数，他坦言其难以解释并建议查阅论文，进而总结该定理旨在解释常规训练中梯度为何极小，遇到难以展开的细节果断略过，直接抛出论文，有效保障了授课节奏。

元宝会议助手 刚刚

yanliji 顺势抛出第二个核心问题，即为何不能简单粗暴地调大学习率来解决问题，这直击了理论推导与实际落地的矛盾点。

针对该疑问，他揭示了语言模型训练存在梯度不规则现象，指出各层梯度范数波动极大，若盲目使用大学习率极易导致特定层梯度爆炸，可见模型各层对大学习率的耐受度参差不齐，强行拉满极易引发训练崩盘。

元宝会议助手 刚刚

yanliji 指出LM Head层存在列间梯度范数差异极大的问题，部分列的数值可达其他列的十倍甚至百倍，这种极端的数值分布，直接成了SGD大学习率下的“爆雷”隐患。

随后，他明确该层作为神经网络输出层的属性，其行数对应内在维度，列数对应总词元数，并预告后续将详解其作用，先抛出异常现象，再点明结构，典型的“先抛问题后给解法”的教学节奏。

我正在听，2分钟后生成总结... 立即总结

元宝会议助手
洞察讨论观点，总结纪要及待办

Illustration: Clipping is Targeted, Not Aggressive

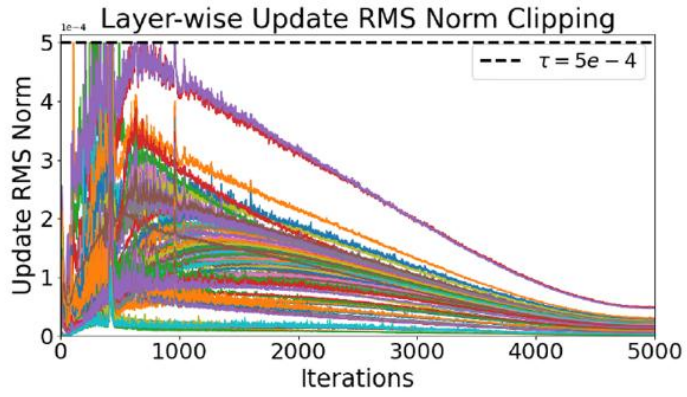

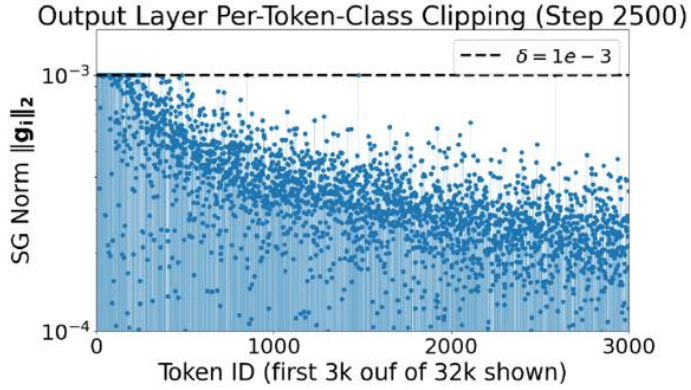

LLaMA-130M. (Left) Type-I clipping: layer-wise RMS update norms; only the spiking layers are clipped. (Right) Type-II clipping: per-token-class norms; only the heavy-tail tokens are clipped.

- Clipping targets the two identified irregularities and leaves the vast majority of gradients untouched.
- This is structure-aware clipping, motivated by the diagnosis.

会议详情 16:03
yanliji正在共享屏幕
演讲者布局 设置
元宝纪要
正在讲话:
会议概览
本次会议旨在探讨SGD和Nesterov加速器在大语言模型训练中的有效性，并分析其表现不佳的原因及相应的解决方案。
小结
针对该疑问，他揭示了语言模型训练存在梯度不规则现象，指出各层梯度范数波动极大，若盲目使用大学习率极易导致特定层梯度爆炸，可见模型各层对大学习率的耐受度参差不齐，强行拉满极易引发训练崩盘。
元宝会议助手 刚刚
yanliji 指出LM Head层存在列间梯度范数差异极大的问题，部分列的数值可达其他列的十倍甚至百倍，这种极端的数值分布，直接成了SGD大学习率下的“爆雷”隐患。
随后，他明确该层作为神经网络输出层的属性，其行数对应内在维度，列数对应总词元数，并预告后续将详解其作用，先抛出异常现象，再点明结构，典型的“先抛问题后给解法”的教学节奏。
元宝会议助手 刚刚
yanliji 指出LM Head矩阵中，高频词对应的列向量范数极大，呈现出“词频越高，向量越大”的规律，这直接点破了数据分布不均带来的底层隐患。
随之，他进一步强调高频词会导致单类词梯度范数相差3至4个数量级，进而在训练中占据绝对主导地位，说白了，高频词成了训练中的“霸道总裁”，直接挤占了其他词的生存空间。
基于此，他得出结论：这种极端的不规则性会直接限制SGD大学习率的使用，否则极易引发模型崩溃，可见高频词不仅抢资源，还成了模型调参的“紧箍咒”。
我正在听，2分钟后生成总结... 立即总结
元宝会议助手
洞察讨论观点，总结纪要及待办
批注
说点什么...
选择音频 开启视频 共享屏幕 成员(25) 邀请 聊天 录制 元宝纪要 应用 离开会议

SGD-LL: Pre-Training Experiment Results

	130M (2.6B tok)				**350M** (7.8B tok)				**1B** (20B tok)			
	V. loss	PPL	LR	$\|w^T - w^0\|_F$	V. loss	PPL	LR	$\|w^T - w^0\|_F$	V. loss	PPL	LR	$\|w^T - w^0\|_F$
Adam	3.11	22.46	3×10^{-3}	1.3×10^{4}	2.78	16.09	2×10^{-3}	6.7×10^{5}	2.51	12.32	2×10^{-3}	7.2×10^{5}
SGD	5.07	158.90	0.5	3.4×10^{2}	4.14	63.22	0.5	5.2×10^{3}	3.95	51.87	0.5	6.2×10^{3}
SGD-LL	**3.24**	25.70	100	3.9×10^{3}	**2.87**	17.35	200	1.1×10^{5}	**2.60**	13.47	300	1.3×10^{5}

LLaMA on C4. $\tau = 5\times10^{-4}$ (130M, 350M), $\tau = 2\times10^{-4}$ (1B); $\delta = 10^{-3}$.

- SGD-LL admits LR $\in \{100, 200, 300\}$ across scales — 200–600$\times$ vanilla SGD.
- Adam-vs-SGD perplexity gap shrinks from $\sim$ 50% down to $\sim$ 3.5% (130M, 1B).

会议详情 16:54 yanliji正在共享屏幕
演讲者布局 设置
正在讲话: yanliji;
元宝纪要
会议概览
本次会议旨在探讨SGD和Nesterov加速器在大语言模型训练中的有效性，并分析其表现不佳的原因及相应的解决方案。
小结
随后，他明确该层作为神经网络输出层的属性，其行数对应内在维度，列数对应总词元数，并预告后续将详解其作用，**先抛出异常现象，再点明结构，典型的“先抛问题后给解法”的教学节奏。**
元宝会议助手 刚刚
yanliji 指出LM Head矩阵中，高频词对应的列向量范数极大，呈现出“词频越高，向量越大”的规律，**这直接点破了数据分布不均带来的底层隐患。**
随之，他进一步强调高频词会导致单类词梯度范数相差3至4个数量级，进而在训练中占据绝对主导地位，**说白了，高频词成了训练中的“霸道总裁”，直接挤占了其他词的生存空间。**
基于此，他得出结论：这种极端的不规则性会直接限制SGD大学习率的使用，否则极易引发模型崩溃，**可见高频词不仅抢资源，还成了模型调参的“紧箍咒”。**
元宝会议助手 刚刚
yanliji 明确了针对高频token和大梯度层的裁剪方案，指出该操作旨在以极简方式修复SGD，使绝大多数层维持常规SGD训练，**可见裁剪并非大改底层逻辑，而是精准切除异常值，主打一个低成本干预。**
随后，他结合图表指出裁剪仅作用于超出阈值的少数情况，并回顾了前文提及的两种裁剪类型，**这说明裁剪机制具备高度针对性，有效避免了“一刀切”式的过度干预。**
我正在听，2分钟后生成总结... 立即总结
元宝会议助手
洞察讨论观点，总结纪要及待办
批注
说点什么...
选择音频 开启视频 共享屏幕 成员(25) 邀请 聊天 录制 元宝纪要 应用 离开会议

SGD-LL: Training Curves Track Adam

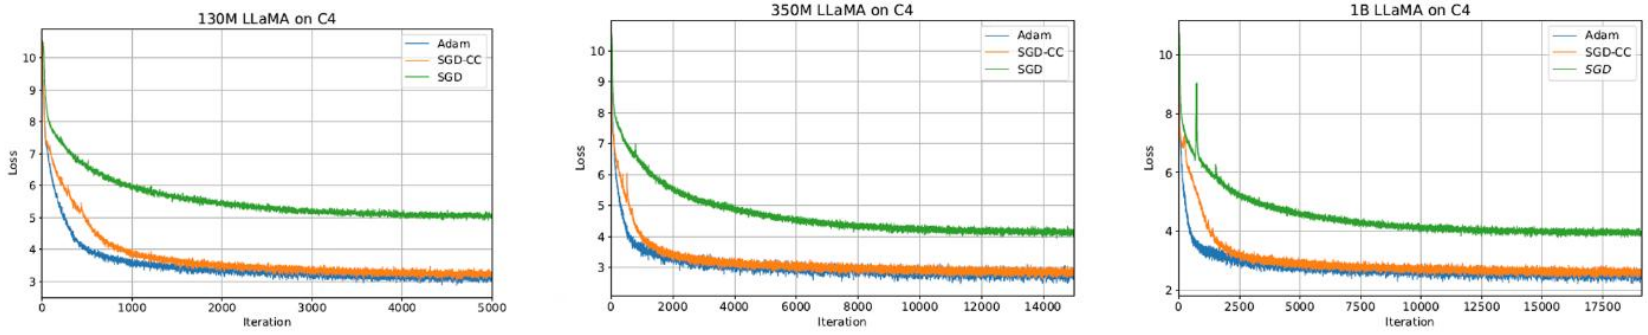

Training-loss evolution across LLaMA 130M / 350M / 1B; token batch size 0.5M–1M. SGD-LL trajectory closely tracks Adam.

Takeaway (Folk wisdom 1, revisited)

SGD's failure in LLM pre-training is not a property of the loss landscape, and not a fundamental limitation. It is a consequence of the structure of the LLM stochastic gradient (small global norm + a few loud directions). Respect that structure, and then SGD with a large LR can significantly close the gap.

会议详情 17:45
yanliji正在共享屏幕
演讲者布局 设置
元宝纪要
正在讲话: yanliji;
会议概览
本次会议旨在探讨SGD及Nesterov加速器在大语言模型训练中的有效性，并通过分析梯度特性及提出简化修复方案，论证了经典优化方法在新场景下的潜力。
随后，他明确该层作为神经网络输出层的属性，其行数对应内在维度，列数对应总词元数，并预告后续将详解其作用，**先抛出异常现象，再点明结构，典型的“先抛问题后给解法”的教学节奏。**
元宝会议助手 刚刚
yanliji 指出LM Head矩阵中，高频词对应的列向量范数极大，呈现出“词频越高，向量越大”的规律，**这直接点破了数据分布不均带来的底层隐患。**
随之，他进一步强调高频词会导致单类词梯度范数相差3至4个数量级，进而在训练中占据绝对主导地位，**说白了，高频词成了训练中的“霸道总裁”，直接挤占了其他词的生存空间**。
基于此，他得出结论：这种极端的不规则性会直接限制SGD大学习率的使用，否则极易引发模型崩溃，**可见高频词不仅抢资源，还成了模型调参的“紧箍咒”。**
元宝会议助手 刚刚
yanliji 明确了针对高频token和大梯度层的裁剪方案，指出该操作旨在以极简方式修复SGD，使绝大多数层维持常规SGD训练，**可见裁剪并非大改底层逻辑，而是精准切除异常值，主打一个低成本干预。**
随后，他结合图表指出裁剪仅作用于超出阈值的少数情况，并回顾了前文提及的两种裁剪类型，**这说明裁剪机制具备高度针对性，有效避免了“一刀切”式的过度干预。**
我正在听，2分钟后生成总结... 立即总结
元宝会议助手
洞察讨论观点，总结纪要及待办
批注
说点什么...
选择音频 开启视频 共享屏幕 成员(25) 邀请 聊天 录制 元宝纪要 应用 离开会议

Subsequent Community Interests on SGD Pre-training

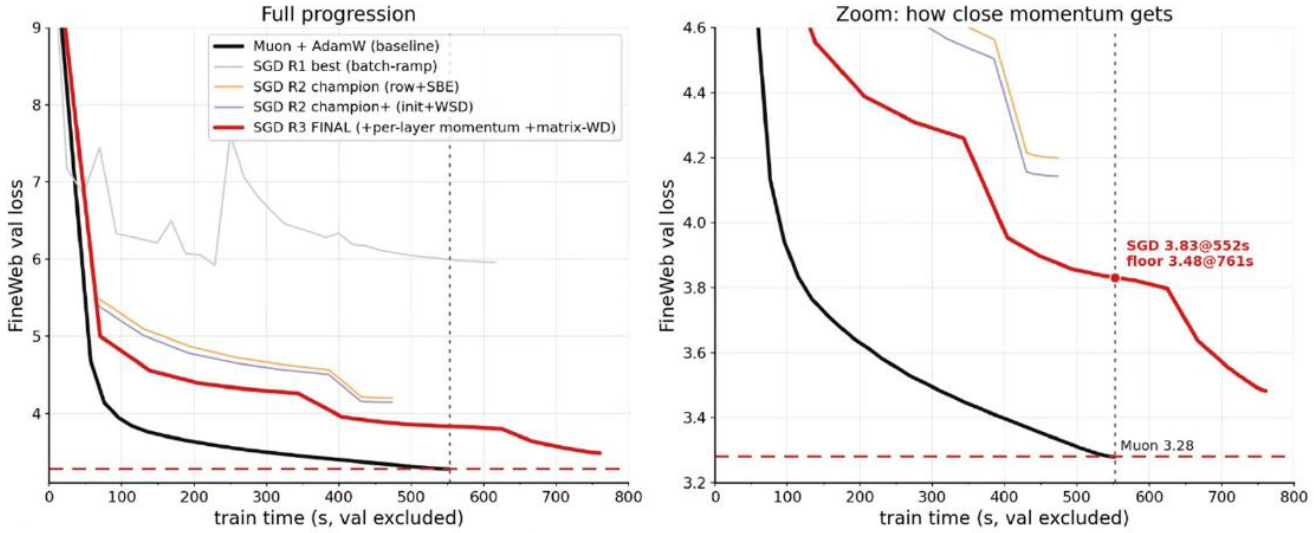

Figure: Momentum SGD with multiple checkpoints and extreme tuning on learning rate schedule on NanoGPT benchmark. Credits to Dimitris Papailiopoulos's X post.

- SGD with careful control can catch up with pre-conditioned optimizers.

会议详情 18:25
yanliji正在共享屏幕
演讲者布局 设置
元宝纪要
正在讲话:
会议概览
本次会议旨在探讨SGD及Nesterov加速器在大语言模型训练中的有效性，并通过分析梯度特性及提出简化修复方案，论证了经典优化方法在新场景下的潜力。
随之，他进一步强调高频词会导致单类词梯度范数相差3至4个数量级，进而在训练中占据绝对主导地位，**说白了，高频词成了训练中的“霸道总裁”，直接挤占了其他词的生存空间**。
基于此，他得出结论：这种极端的不规则性会直接限制SGD大学习率的使用，否则极易引发模型崩溃，**可见高频词不仅抢资源，还成了模型调参的“紧箍咒”**。
元宝会议助手 刚刚
yanliji 明确了针对高频token和大梯度层的裁剪方案，指出该操作旨在以极简方式修复SGD，使绝大多数层维持常规SGD训练，**可见裁剪并非大改底层逻辑，而是精准切除异常值，主打一个低成本干预**。
随后，他结合图表指出裁剪仅作用于超出阈值的少数情况，并回顾了前文提及的两种裁剪类型，**这说明裁剪机制具备高度针对性，有效避免了“一刀切”式的过度干预**。
元宝会议助手 刚刚
yanliji 通过图表对比验证，经裁剪优化的SGD性能已逼近Adam，大幅缩小了与基础SGD的验证损失差距，**这表明SGD的失败并非底层逻辑缺陷，而是受限于语言模型随机梯度的结构特性**。
随后，yanliji 抛出核心结论：SGD在LLaMA训练中的失效并非损失景观或根本性限制所致，纯粹是随机梯度结构问题，**相当于把SGD的“锅”从算法本身甩到了数据特性上**。
我正在听，2分钟后生成总结... 立即总结
元宝会议助手
洞察讨论观点，总结纪要及待办
批注
说点什么...
选择音频 开启视频 共享屏幕 成员(25) 邀请 聊天 录制 元宝纪要 应用 离开会议

From Diagnosis to a Memory-Efficient Optimizer

Goal. Turn the diagnosis into a practical, memory-efficient optimizer for pre-training.

- Memory bottleneck (LLaMA-7B example, BF16, single batch):
  - Parameters 14 GB + Gradient 14 GB + Activations 2 GB
  - Adam states (m, v): 28 GB $\Rightarrow$ Total 58 GB $>$ A100 40 GB.

LLaMA-7B memory estimate
(Zhao+ ICML'24)

- Trainable Parameters: 14GB
- Adam States (M,V): 28GB
- Gradients: 14GB
- Activations: 2GB
- Total: 58GB

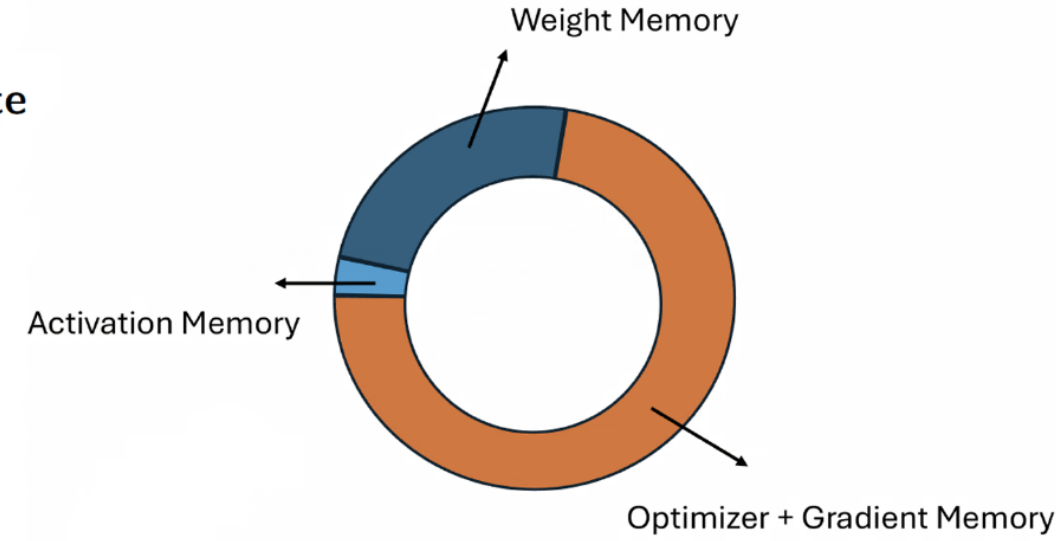

会议详情 18:59
yanliji正在共享屏幕
演讲者布局
设置
元宝纪要
正在讲话: yanliji;
会议概览
本次会议讨论了SGD和Nesterov加速器在大语言模型训练中的表现，并提出了针对性的优化方案。
小结
随之，他进一步强调高频词会导致单类词梯度范数相差3至4个数量级，进而在训练中占据绝对主导地位，说白了，高频词成了训练中的“霸道总裁”，直接挤占了其他词的生存空间。
基于此，他得出结论：这种极端的不规则性会直接限制SGD大学习率的使用，否则极易引发模型崩溃，可见高频词不仅抢资源，还成了模型调参的“紧箍咒”。
元宝会议助手 刚刚
yanliji 明确了针对高频token和大梯度层的裁剪方案，指出该操作旨在以极简方式修复SGD，使绝大多数层维持常规SGD训练，可见裁剪并非大改底层逻辑，而是精准切除异常值，主打一个低成本干预。
随后，他结合图表指出裁剪仅作用于超出阈值的少数情况，并回顾了前文提及的两种裁剪类型，这说明裁剪机制具备高度针对性，有效避免了“一刀切”式的过度干预。
元宝会议助手 刚刚
yanliji 通过图表对比验证，经裁剪优化的SGD性能已逼近Adam，大幅缩小了与基础SGD的验证损失差距，这表明SGD的失败并非底层逻辑缺陷，而是受限于语言模型随机梯度的结构特性。
随后，yanliji 抛出核心结论：SGD在LLaMA训练中的失效并非损失景观或根本性限制所致，纯粹是随机梯度结构问题，相当于把SGD的“锅”从算法本身甩到了数据特性上。
我正在听，2分钟后生成总结... 立即总结
元宝会议助手
洞察讨论观点，总结纪要及待办
yanliji正在共享

Motivation

- **Growing literature on memory-efficient optimizers**: e.g., GaLore (ICML'24), Apollo (MLSys'25), SWAN (ICML'25), Fira, SinkGD (NeurIPS'25).
- Recent optimizers start to directly remove the optimizer states, e.g., Muon (2024), Scion, Swan (ICML'25).
- Most **existing works** either **build on-top of Adam** or use computationally heavy components.
- **No systematic study** to identify the most essential algorithmic components beyond plain SGD.

Question

Can we design a memory-efficient optimizer with minimum modifications to plain SGD (even without momentum) and SOTA pre-training performance?

会议详情 20:25 yanliji正在共享屏幕
演讲者布局 设置
元宝纪要
正在讲话:
会议概览
本次会议讨论了SGD和Nesterov加速器在大语言模型训练中的表现，并提出了针对性的优化方案。
小结
该操作旨在以极简方式修复SGD，使绝大多数层维持常规SGD训练，可见裁剪并非大改底层逻辑，而是精准切除异常值，主打一个低成本干预。
随后，他结合图表指出裁剪仅作用于超出阈值的少数情况，并回顾了前文提及的两种裁剪类型，这说明裁剪机制具备高度针对性，有效避免了“一刀切”式的过度干预。
元宝会议助手 刚刚
yanliji 通过图表对比验证，经裁剪优化的SGD性能已逼近Adam，大幅缩小了与基础SGD的验证损失差距，这表明SGD的失败并非底层逻辑缺陷，而是受限于语言模型随机梯度的结构特性。
随后，yanliji 抛出核心结论：SGD在LLaMA训练中的失效并非损失景观或根本性限制所致，纯粹是随机梯度结构问题，相当于把SGD的“锅”从算法本身甩到了数据特性上。
元宝会议助手 刚刚
yanliji 坦言当前算法因效率不及AdamW而缺乏实用价值，但指出后续社区研究已通过参数调优在Nano GPT基准上成功弥合了SGD与主流优化器的性能差距，这说明SGD的潜力已被验证，其性能瓶颈并非无解。
进而，yanliji 强调该研究的实用价值在于两点：一是SGD未来仍有望应用于模型训练，二是其底层直觉可迁移至其他领域，可见这项研究的核心价值不在于当下替代，而在于提供底层逻辑启发。
我正在听，2分钟后生成总结... 立即总结
元宝会议助手
洞察讨论观点，总结纪要及待办
批注
说点什么...
选择音频 开启视频 共享屏幕 成员(25) 邀请 聊天 录制 元宝纪要 应用 离开会议

Existing Memory-Efficient Optimizers

Focus on memory-efficient variations of Adam

- Pioneered by GaLore (ICML'24), focus on compressing the Adam optimizer states.
- **Main idea**: Project the gradient $G \in \mathbb{R}^{m\times n}$ into low-rank: $P^T G$, $P \in \mathbb{R}^{m\times r}$; compute Adam states in low-dim; then project-up again.

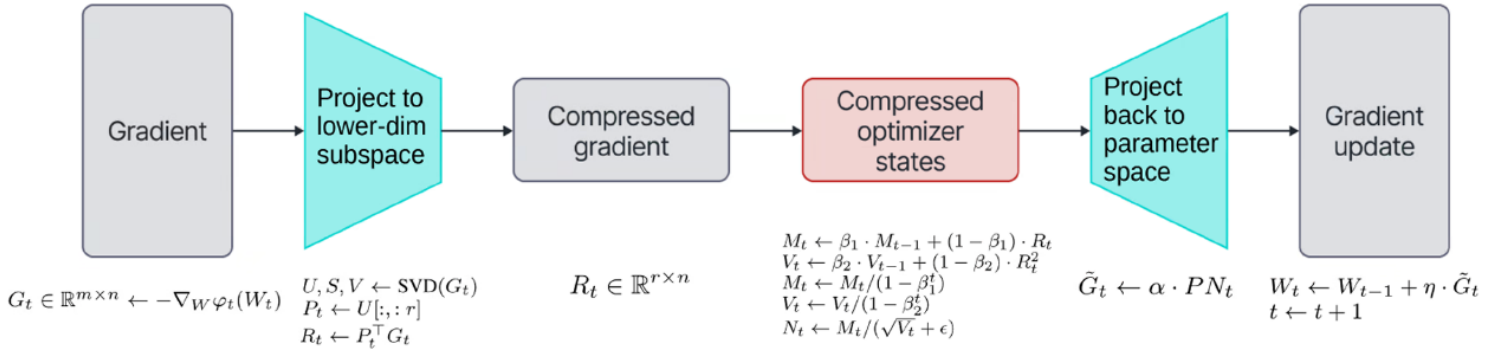

批注

元宝纪要
正在讲话: yanliji;
会议概览
本次会议讨论了SGD和Nesterov加速器在大语言模型训练中的表现，并提出了针对性的优化方案。
小结
yanliji 坦言当前算法因效率不及AdamW而缺乏实用价值，但指出后续社区研究已通过参数调优在Nano GPT基准上成功弥合了SGD与主流优化器的性能差距，这说明SGD的潜力已被验证，其性能瓶颈并非无解。
进而，yanliji 强调该研究的实用价值在于两点：一是SGD未来仍有望应用于模型训练，二是其底层直觉可迁移至其他领域，可见这项研究的核心价值不在于当下替代，而在于提供底层逻辑启发。
元宝会议助手 刚刚
yanliji 指出SGD因仅存储梯度而具备极高的内存效率，反观Adam需额外存储动量参数，内存开销至少翻倍，这直接点透了SGD的核心优势，即极简架构带来的低资源门槛。
随后他以Llama 7B模型为例，说明其训练需占用58GB显存，已超出单张40GB显卡的承载极限，可见显存瓶颈已成为大模型训练的硬伤，迫使业界必须寻求更轻量的优化方案。
元宝会议助手 刚刚
yanliji 指出当前业界优化器多基于Adam做减法，而缺乏针对SGD本质组件的系统性研究，这暴露出当前主流优化思路存在路径依赖，一味做减法已触及瓶颈。
基于此，他提出“做加法”的新思路，即在SGD基础上添加必要组件，旨在以最小改动实现内存高效且性能有竞争力的优化器，相当于把复杂的“大手术”变成精准的“微整形”，兼顾了性能与成本。
我正在听，2分钟后生成总结... 立即总结
元宝会议助手
洞察讨论观点，总结纪要及待办
说点什么...
选择音频 开启视频 共享屏幕 成员(26) 邀请 聊天 录制 元宝纪要 应用 离开会议

Pre-training optimizer: From SGD to Adam

Dissecting the key components of Adam:

Algorithm 1 SGD (one step)

$$g^t \leftarrow \nabla \ell(\theta^t; \xi_t)$$
$$\theta^{t+1} \leftarrow \theta^t - \eta g^t$$

Algorithm 2 sign SGD (one step)

$$g^t \leftarrow \nabla \ell(\theta^t; \xi_t)$$
$$\theta^{t+1} \leftarrow \theta^t - \eta \frac{g^t}{\sqrt{g^t \odot g^t}}$$

Algorithm 3 Adam (one step)

$$g^t \leftarrow \nabla \ell(\theta^t; \xi_t)$$
$$m^t \leftarrow \beta_1 m^t + (1-\beta_1) g^t$$
$$v^t \leftarrow \beta_2 v^t + (1-\beta_2) g^t \odot g^t$$
$$\theta^{t+1} \leftarrow \theta^t - \eta \frac{\sqrt{1-\beta_2^t}}{1-\beta_1^t} \frac{m^t}{\sqrt{v^t}+\epsilon}$$

From SGD to Adam
- Gradient Normalization
- Exponential Moving Average (EMA)/Momentum

会议详情 23:07
yanliji正在共享屏幕
演讲者布局 设置
元宝纪要
正在讲话:
会议概览
本次会议讨论了SGD和Nesterov加速器在大语言模型训练中的表现，并提出了针对性的解决方案。
小结
yanliji 指出SGD因仅存储梯度而具备极高的内存效率，反观Adam需额外存储动量参数，内存开销至少翻倍，这直接点透了SGD的核心优势，即极简架构带来的低资源门槛。
随后他以Llama 7B模型为例，说明其训练需占用58GB显存，已超出单张40GB显卡的承载极限，可见显存瓶颈已成为大模型训练的硬伤，迫使业界必须寻求更轻量的优化方案。
元宝会议助手 刚刚
yanliji 指出当前业界优化器多基于Adam做减法，而缺乏针对SGD本质组件的系统性研究，这暴露出当前主流优化思路存在路径依赖，一味做减法已触及瓶颈。
基于此，他提出“做加法”的新思路，即在SGD基础上添加必要组件，旨在以最小改动实现内存高效且性能有竞争力的优化器，相当于把复杂的“大手术”变成精准的“微整形”，兼顾了性能与成本。
元宝会议助手 刚刚
yanliji 以2024年的Galore方法为例，阐述了现有低内存优化器的设计思路：对梯度进行SVD分解并投影到低维空间，可见，当前主流方案是通过降维来压缩状态，与上文提出的“加法”思路形成鲜明对比。
随后，yanliji 指出该方法在低维空间中构建动量等状态并计算更新方向，从而大幅降低了优化器状态的内存开销，说白了，就是把复杂的计算搬到“小房间”里做，以此实现内存减负。
我正在听，2分钟后生成总结... 立即总结
元宝会议助手
洞察讨论观点，总结纪要及待办
批注
说点什么...
选择音频 开启视频 共享屏幕 成员(26) 邀请 聊天 录制 元宝纪要 应用 离开会议

Key components of Adam I: Grad-normalization

- Gradient normalization: control the magnitude of the update
- Variety of gradient normalization schemes, including:

$$\text{Singular-value normalization:} \quad UV^\top, \quad \text{where } G = U\Sigma V^\top \text{ (SVD)}$$

$$\text{Column-wise normalization:} \quad \left[\frac{\text{col}_1(G)}{\|\text{col}_1(G)\|}, \ldots, \frac{\text{col}_n(G)}{\|\text{col}_n(G)\|}\right]$$

$$\text{Row-wise normalization:} \quad \left[\frac{\text{row}_1(G)^\top}{\|\text{row}_1(G)\|}, \ldots, \frac{\text{row}_m(G)^\top}{\|\text{row}_m(G)\|}\right]^\top$$

$$\text{Sign normalization:} \quad \text{sign}(G)$$

where $G \in \mathbb{R}^{d_{\text{in}} \times d_{\text{out}}}$, therefore row- and column-normalizations correspond to normalizing along the input and output dimensions, respectively.

元宝纪要
正在讲话:
会议概览
本次会议讨论了SGD和Nesterov加速器在大语言模型训练中的表现，并提出了针对性的优化方案。
小结
yanliji 指出当前主流优化器多基于Adam做减法，而缺乏针对SGD本质组件的系统性研究，这暴露出当前主流优化思路存在路径依赖，一味做减法已触及瓶颈。
基于此，他提出“做加法”的新思路，即在SGD基础上添加必要组件，旨在以最小改动实现内存高效且性能有竞争力的优化器，相当于把复杂的“大手术”变成精准的“微整形”，兼顾了性能与成本。
元宝会议助手 刚刚
yanliji 以2024年的Galore方法为例，阐述了现有低内存优化器的设计思路：对梯度进行SVD分解并投影到低维空间，可见，当前主流方案是通过降维来压缩状态，与上文提出的“加法”思路形成鲜明对比。
随后，yanliji 指出该方法在低维空间中构建动量等状态并计算更新方向，从而大幅降低了优化器状态的内存开销，说白了，就是把复杂的计算搬到“小房间”里做，以此实现内存减负。
元宝会议助手 刚刚
yanliji 提出通过逐步降维来测试算法极限，并梳理了优化器演进脉络，从最简单的SGD到包含M和V状态的Adam，这其实是在用“控制变量法”拆解复杂算法，把黑盒问题变成白盒推演。
随后，他引入Science Gd作为Adam的变体，指出该算法移除了部分更新机制，相当于在SGD和Adam之间搭了个台阶，方便大家看清多出来的状态到底起了什么作用。
我正在听，2分钟后生成总结... 立即总结
元宝会议助手
洞察讨论观点，总结纪要及待办

Key components of Adam I: Grad-normalization

Efficiency of different gradient normalizations (time in ms)

dimension d	1024	2048	4096
singular-value	79.77	354.27	1958.66
singular-value (NS)	6.03	7.00	14.41
column-wise	0.10	0.12	0.17
row-wise	0.09	0.11	0.13
sign	0.03	0.03	0.03

- Time (ms) to normalize a square torch matrix on NVIDIA A40 GPU.
- Singular-value variants are at least 50× more expensive than the rest.

正在讲话:

会议概览

本次会议讨论了SGD和Nesterov加速器在大语言模型训练中的表现，并提出了针对性的优化方案。

小结

yanliji 以2024年的Galore方法为例，阐述了现有低内存优化器的设计思路：对梯度进行SVD分解并投影到低维空间，可见，当前主流方案是通过降维来压缩状态，与上文提出的“加法”思路形成鲜明对比。

随后，yanliji 指出该方法在低维空间中构建动量等状态并计算更新方向，从而大幅降低了优化器状态的内存开销，说白了，就是把复杂的计算搬到“小房间”里做，以此实现内存减负。

元宝会议助手 刚刚

yanliji 提出通过逐步降维来测试算法极限，并梳理了优化器演进脉络，从最简单的SGD到包含M和V状态的Adam，这其实是在用“控制变量法”拆解复杂算法，把黑盒问题变成白盒推演。

随后，他引入Science Gd作为Adam的变体，指出该算法移除了部分更新机制，相当于在SGD和Adam之间搭了个台阶，方便大家看清多出来的状态到底起了什么作用。

元宝会议助手 刚刚

yanliji 详细拆解了Sign SGD算法，指出该算法仅保留Adam中的V更新，通过符号算子将梯度归一化为正负一，这其实就是把复杂的梯度更新简化成了“非黑即白”的二元方向判断。

随后，他提炼出从SGD演进至Adam的两个核心组件：梯度归一化与指数移动平均，相当于把复杂的优化器演进，拆解成了两个最底层的积木。

我正在听，2分钟后生成总结... 立即总结

元宝会议助手
洞察讨论观点，总结纪要及待办

Key components of Adam I: Grad-normalization

Performance of different gradient normalizations (perplexity)

	60M	130M	350M
Tokens	1.4B	2.6B	7.8B
Adam	28.77	22.20	16.80
singular-value (NS)	34.15	25.25	18.73
column-wise	39.89	28.85	20.38
row-wise	79.27	37.67	21.63
sign	54.36	40.42	27.95

- Singular-value (NS) performs best, but has reduced throughput (10-20%).
- Column-wise comes second but is more time-efficient.

会议详情 26:17
yanliji正在共享屏幕
演讲者布局 设置
元宝纪要
正在讲话: yanliji;
会议概览
本次会议讨论了SGD和Nesterov加速器在大语言模型训练中的表现，并提出了针对性的优化方案。
小结
化器的设计思路：对梯度进行SVD分解并投影到低维空间，可见，当前主流方案是通过降维来压缩状态，与上文提出的“加法”思路形成鲜明对比。
随后，yanliji 指出该方法在低维空间中构建动量等状态并计算更新方向，从而大幅降低了优化器状态的内存开销，说白了，就是把复杂的计算搬到“小房间”里做，以此实现内存减负。
元宝会议助手 刚刚
yanliji 提出通过逐步降维来测试算法极限，并梳理了优化器演进脉络，从最简单的SGD到包含M和V状态的Adam，这其实是在用“控制变量法”拆解复杂算法，把黑盒问题变成白盒推演。
随后，他引入Science Gd作为Adam的变体，指出该算法移除了部分更新机制，相当于在SGD和Adam之间搭了个台阶，方便大家看清多出来的状态到底起了什么作用。
元宝会议助手 刚刚
yanliji 详细拆解了Sign SGD算法，指出该算法仅保留Adam中的V更新，通过符号算子将梯度归一化为正负一，这其实就是把复杂的梯度更新简化成了“非黑即白”的二元方向判断。
随后，他提炼出从SGD演进至Adam的两个核心组件：梯度归一化与指数移动平均，相当于把复杂的优化器演进，拆解成了两个最底层的积木。
我正在听，2分钟后生成总结... 立即总结
元宝会议助手
洞察讨论观点，总结纪要及待办
yanliji正在共享

Why Column-wise Normalization

The output (lm_head) layer is special. It maps the last hidden state to vocabulary logits; each column of G corresponds to one of $|V|$ tokens.

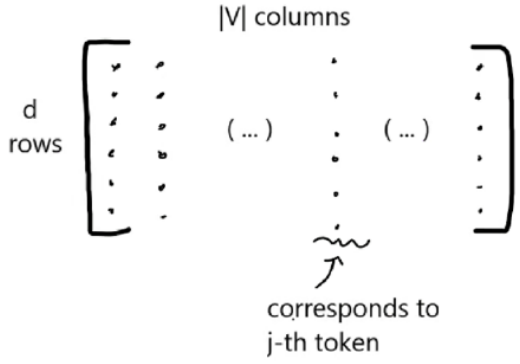

Sketch: last-layer grad matrix; each column = one token class.

- Per-token-class grad norms span 3–4 orders of magnitude (frequent tokens dominate).
- Column-wise normalization equalizes per-class contributions — exactly the Type-II fix from the diagnosis.
- Row-wise / sign normalization do not respect this per-column structure; singular-value is too expensive.

会议详情 27:29
yanliji正在共享屏幕
演讲者布局 设置
元宝纪要
正在讲话: yanliji;
会议概览
本次会议讨论了SGD和Nesterov加速器在大语言模型训练中的表现，并提出了针对性的优化方案。
小结
元宝会议助手 3分钟前
yanliji 提出通过逐步降维来测试算法极限，并梳理了优化器演进脉络，从最简单的SGD到包含M和V状态的Adam，这其实是在用“控制变量法”拆解复杂算法，把黑盒问题变成白盒推演。
随后，他引入Science Gd作为Adam的变体，指出该算法移除了部分更新机制，相当于在SGD和Adam之间搭了个台阶，方便大家看清多出来的状态到底起了什么作用。
元宝会议助手 刚刚
yanliji 详细拆解了Sign SGD算法，指出该算法仅保留Adam中的V更新，通过符号算子将梯度归一化为正负一，这其实就是把复杂的梯度更新简化成了“非黑即白”的二元方向判断。
随后，他提炼出从SGD演进至Adam的两个核心组件：梯度归一化与指数移动平均，相当于把复杂的优化器演进，拆解成了两个最底层的积木。
元宝会议助手 刚刚
yanliji 列举了奇异值分解及行列归一化等其他梯度归一化方法，并探讨其有效性，可见在基础算法之外，学术界还在不断挖掘更优的优化变体。
随后，yanliji 对比了各方法的计算开销，指出SVD极其昂贵，而行列归一化成本极低，这直接点透了工程落地的核心矛盾：理论再完美，跑不动也是白搭。
我正在听，2分钟后生成总结... 立即总结
元宝会议助手
洞察讨论观点，总结纪要及待办
批注
说点什么...
选择音频 开启视频 共享屏幕 成员(23) 邀请 聊天 录制 元宝纪要 应用 离开会议

Key components of Adam II: EMA

- EMA is the origin of most of the memory overheads!
- Can we apply EMA more frugally? Lets estimate per-layer grad variance:

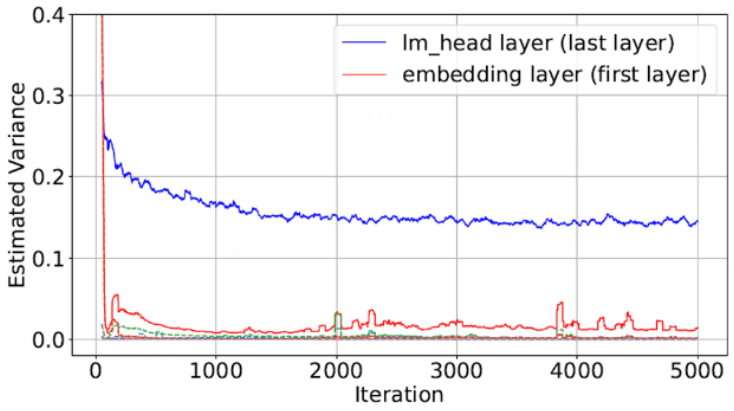

(a) SGD-col-norm

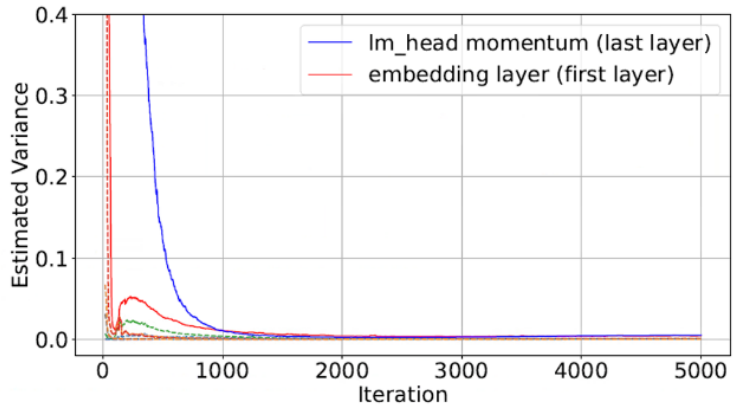

(b) SGD-col-norm-mmt-last

- (a) Gradient variance of the last-layer much higher than the rest.
- (b) Applying momentum only to last layer reduces its variance!

会议详情 27:53
yanliji正在共享屏幕
演讲者布局 设置
元宝纪要
正在讲话: yanliji;
会议概览
本次会议讨论了SGD和Nesterov加速器在大语言模型训练中的表现，并提出了针对性的优化方案。
小结
元宝会议助手 刚刚
yanliji 详细拆解了Sign SGD算法，指出该算法仅保留Adam中的V更新，通过符号算子将梯度归一化为正负一，这其实就是把复杂的梯度更新简化成了“非黑即白”的二元方向判断。
随后，他提炼出从SGD演进至Adam的两个核心组件：梯度归一化与指数移动平均，相当于把复杂的优化器演进，拆解成了两个最底层的积木。
元宝会议助手 刚刚
yanliji 列举了奇异值分解及行列归一化等其他梯度归一化方法，并探讨其有效性，可见在基础算法之外，学术界还在不断挖掘更优的优化变体。
随后，yanliji 对比了各方法的计算开销，指出SVD极其昂贵，而行列归一化成本极低，这直接点透了工程落地的核心矛盾：理论再完美，跑不动也是白搭。
元宝会议助手 刚刚
yanliji 对比了各优化方法的性能，指出SVD表现最佳但耗时，列归一化次之且更高效，行归一化及Sign方法表现较差，可见在算法优化中，性能与计算成本往往难以兼得，需做取舍。
随后，yanliji 探究了列归一化优于行归一化的原因，指出关键在于最后一层中“列”具有特定的物理意义，这说明理解模型底层结构，是解释算法表现差异的核心钥匙。
我正在听，2分钟后生成总结... 立即总结
元宝会议助手
洞察讨论观点，总结纪要及待办
批注
说点什么...
选择音频 开启视频 共享屏幕 成员(23) 邀请 聊天 录制 元宝纪要 应用 离开会议

Theoretical insights: Layer-wise grad variance

Denote the optimization problem of the LLM pretraining as

$$\min_{\theta=[\theta_1,\ldots,\theta_L]} \ell(\theta) := \frac{1}{n}\sum_{i=1}^{n} \ell(\theta;\xi_i) \tag{1}$$

Aslo consider the following SGD-M algorithm to solve (1):

$$\begin{aligned} m_l^t &= \beta_l m_l^{t-1} + (1-\beta_l) g^t,\ g^t = \nabla_{\theta_l} \ell(\theta^t;\xi_t) \\ \theta_l^{t+1} &= \theta_l^t - \eta_l m_l^t \end{aligned} \tag{2}$$

- Turns out momentum helps the most for the layers with larger gradient variances.

会议详情 29:22 | yanliji正在共享屏幕 | 演讲者布局 | 设置
元宝纪要
正在讲话:
会议概览
本次会议讨论了SGD和Nesterov加速器在大语言模型训练中的应用，分析了SGD表现不佳的原因，并提出了相应的解决方案。
元宝会议助手 刚刚
yanliji 列举了奇异值分解及行列归一化等其他梯度归一化方法，并探讨其有效性，可见在基础算法之外，学术界还在不断挖掘更优的优化变体。
随后，yanliji 对比了各方法的计算开销，指出SVD极其昂贵，而行列归一化成本极低，这直接点透了工程落地的核心矛盾：理论再完美，跑不动也是白搭。
元宝会议助手 刚刚
yanliji 对比了各优化方法的性能，指出SVD表现最佳但耗时，列归一化次之且更高效，行归一化及Sign方法表现较差，可见在算法优化中，性能与计算成本往往难以兼得，需做取舍。
随后，yanliji 探究了列归一化优于行归一化的原因，指出关键在于最后一层中“列”具有特定的物理意义，这说明理解模型底层结构，是解释算法表现差异的核心钥匙。
元宝会议助手 刚刚
yanliji 总结列归一化优于行归一化的核心在于梯度在token间分布更均匀，并提及后续理论也佐证了该观点，可见列归一化在学术界已具备扎实的理论支撑。
随后，他将议题推进至第二个组件EMA，并重新梳理了其对梯度及梯度平方进行指数平均的核心概念，这表明会议正按部就班地拆解优化器的底层逻辑。
我正在听，2分钟后生成总结... 立即总结
元宝会议助手
洞察讨论观点，总结纪要及待办
批注
说点什么...
选择音频 开启视频 共享屏幕 成员(23) 邀请 聊天 录制 元宝纪要 应用 离开会议

Theoretical insights: Layer-wise grad variance

Theorem

Suppose $\ell(\theta)$ in (1) is lower bounded by ℓ^*, γ-smooth (i.e. $\nabla\ell(\theta)$ is Lipschitz continuous with constant γ), also the stochastic gradient is unbiased $\mathbb{E}_{\xi_t}\nabla_{\theta_l}\ell(\theta^t;\xi_t) = \nabla_{\theta_l}\ell(\theta^t)$ and with bounded variance: $\mathbb{E}_{\xi_t}\|\nabla_{\theta_l}\ell(\theta^t;\xi_t) - \nabla_{\theta_l}\ell(\theta^t)\|^2 \le \sigma_l^2$ for all $l = 1,\dots,L$ and $t = 0,\dots,T-1$. With appropriate choice of hyperparameters $\eta_l \ge \eta$ and $\beta_l \le 1-\delta$ (δ is an absolute constant), we have the following convergence result for update (2):

$$\frac{1}{T}\sum_{t=1}^{T}\sum_{l=1}^{L}\mathbb{E}\|\nabla_l^t\|^2 \le \frac{2L\gamma^{3/2}\mathbb{E}\Delta_1}{\delta^2\sqrt{T}} + \sum_{l=1}^{L}\left(\frac{1-\beta_l}{1+\beta_l}\frac{L\sqrt{\gamma}}{4\sqrt{T}} + \frac{L\gamma^{3/2}}{2\sqrt{T}} + \frac{1-\beta_l}{\beta_l^3}\frac{\gamma^2}{4LT}\right)\frac{\sigma_l^2}{\delta^2} \quad (3)$$

where $\nabla_l^t = \nabla_{\theta_l}\ell(\theta^t;\xi_t)$ and $\Delta_1 = \ell(\theta^1) - \ell^*$.

会议详情 29:36
yanliji正在共享屏幕
演讲者布局 设置
元宝纪要
正在讲话: yanliji;
会议概览
本次会议讨论了SGD和Nesterov加速器在大语言模型训练中的应用，分析了SGD表现不佳的原因，并提出了相应的解决方案。
元宝会议助手 3分钟前
yanliji 列举了奇异值分解及行列归一化等其他梯度归一化方法，并探讨其有效性，可见在基础算法之外，学术界还在不断挖掘更优的优化变体。
随后，yanliji 对比了各方法的计算开销，指出SVD极其昂贵，而行列归一化成本极低，这直接点透了工程落地的核心矛盾：理论再完美，跑不动也是白搭。
元宝会议助手 刚刚
yanliji 对比了各优化方法的性能，指出SVD表现最佳但耗时，列归一化次之且更高效，行归一化及Sign方法表现较差，可见在算法优化中，性能与计算成本往往难以兼得，需做取舍。
随后，yanliji 探究了列归一化优于行归一化的原因，指出关键在于最后一层中“列”具有特定的物理意义，这说明理解模型底层结构，是解释算法表现差异的核心钥匙。
元宝会议助手 刚刚
yanliji 总结列归一化优于行归一化的核心在于梯度在token间分布更均匀，并提及后续理论也佐证了该观点，可见列归一化在学术界已具备扎实的理论支撑。
随后，他将议题推进至第二个组件EMA，并重新梳理了其对梯度及梯度平方进行指数平均的核心概念，这表明会议正按部就班地拆解优化器的底层逻辑。
我正在听，2分钟后生成总结... 立即总结
元宝会议助手
洞察讨论观点，总结纪要及待办
批注
说点什么...
选择音频 开启视频 共享屏幕 成员(23) 邀请 聊天 录制 元宝纪要 应用 离开会议

Theoretical insights: Layer-wise grad variance

Remark

Theorem 1 suggests that β_l's should be all taken to be $1-\delta$. The second term of the right-hand side of (3) takes the form

$$f(x) = \frac{1-x}{1+x} + c\frac{1-x}{x^3},\ c := \frac{\gamma}{L^2 T^{3/2}}$$

where x represents the layer-wise momentum hyperparameter β_l.

$f(x)$ is decreasing in $(0, 1-\delta]$, optimal strategy: $\beta_l = 1-\delta$, for all $l = 1, \cdots L$.

However, since $\sigma_l \approx 0,\ \forall\ l \neq L$ close to zero, to improve memory efficiency, one can take $\beta_l = 0$ for $l = 1, ..., L-1$ and only keep the momentum for the last layer.

会议详情 30:37
yanliji正在共享屏幕
演讲者布局 设置
元宝纪要
正在讲话: yanliji;
会议概览
本次会议讨论了SGD和Nesterov加速器在大语言模型训练中的应用，分析了其性能差距的原因，并提出了相应的优化方案。
元宝会议助手 刚刚
yanliji 对比了各优化方法的性能，指出SVD表现最佳但耗时，列归一化次之且更高效，行归一化及Sign方法表现较差，可见在算法优化中，性能与计算成本往往难以兼得，需做取舍。
随后，yanliji 探究了列归一化优于行归一化的原因，指出关键在于最后一层中“列”具有特定的物理意义，这说明理解模型底层结构，是解释算法表现差异的核心钥匙。
元宝会议助手 刚刚
yanliji 总结列归一化优于行归一化的核心在于梯度在token间分布更均匀，并提及后续理论也佐证了该观点，可见列归一化在学术界已具备扎实的理论支撑。
随后，他将议题推进至第二个组件EMA，并重新梳理了其对梯度及梯度平方进行指数平均的核心概念，这表明会议正按部就班地拆解优化器的底层逻辑。
元宝会议助手 刚刚
yanliji 指出EMA并非全局必需，通过对比各层方差发现，仅最后一层方差较大，对其应用EMA即可大幅降低噪声，这打破了常规认知，相当于给模型做了个“减负”，把算力花在刀刃上。
基于此，他提出仅对最后一层应用动量的猜想，并表示该结论在动量SGD的理论公式中能得到合理解释，可见理论推导与实验数据形成了闭环，为优化策略提供了坚实依据。
我正在听，2分钟后生成总结... 立即总结
元宝会议助手
洞察讨论观点，总结纪要及待办
批注
说点什么...
选择音频 开启视频 共享屏幕 成员(23) 邀请 聊天 录制 元宝纪要 应用 离开会议

Adding momentum to last layer

- Our theoretical result suggests to add **momentum only to last-layer**:

Model Size	**60M**	**130M**	**350M**
Tokens	1.4B	2.6B	7.8B
Adam	28.77	22.20	16.80
singular-value (NS)	34.15	25.25	18.73
column-wise	39.89	28.85	20.38
Singular-val (NS) + mmt-last	31.20	22.33	16.67
Column-wise + mmt-last (ours)	30.81	22.57	16.32

Table: Evaluation perplexity of two normalizations (singular-value and column-wise) when combined with last-layer-momentum (mmt-last).

Column-wise and last-layer momentum close the gap with Adam!

会议详情 31:38
yanliji正在共享屏幕
演讲者布局 设置
元宝纪要
正在讲话:
会议概览
本次会议讨论了SGD和Nesterov加速器在大语言模型训练中的应用，分析了其性能差距的原因，并提出了相应的优化方案。
元宝会议助手 3分钟前
yanliji 总结列归一化优于行归一化的核心在于梯度在token间分布更均匀，并提及后续理论也佐证了该观点，可见列归一化在学术界已具备扎实的理论支撑。
随后，他将议题推进至第二个组件EMA，并重新梳理了其对梯度及梯度平方进行指数平均的核心概念，这表明会议正按部就班地拆解优化器的底层逻辑。
元宝会议助手 刚刚
yanliji 指出EMA并非全局必需，通过对比各层方差发现，仅最后一层方差较大，对其应用EMA即可大幅降低噪声，这打破了常规认知，相当于给模型做了个“减负”，把算力花在刀刃上。
基于此，他提出仅对最后一层应用动量的猜想，并表示该结论在动量SGD的理论公式中能得到合理解释，可见理论推导与实验数据形成了闭环，为优化策略提供了坚实依据。
元宝会议助手 刚刚
yanliji 继续推导收敛边界公式，指出右侧的梯度方差项与层数相关，且受动量参数beta的递增函数影响，这表明动量参数beta越大，方差项的放大效应越明显，对收敛稳定性的影响也越大。
随后，他明确了动量参数beta的取值范围，将其限定在小于1减delta的区间内，这其实是为理论推导划定了安全边界，确保动量机制在可控范围内生效。
我正在听，2分钟后生成总结... 立即总结
元宝会议助手
洞察讨论观点，总结纪要及待办
批注
说点什么...
选择音频 开启视频 共享屏幕 成员(23) 邀请 聊天 录制 元宝纪要 应用 离开会议

SCALE – A Minimalist Pre-training Optimizer

SCALE = **S**tochastic **C**olumn-norm**A**lized **L**ast-layer mom**E**ntum.

Algorithm 1 SCALE: Stochastic Column-normalized Last-layer Momentum

Input: Initialized trainable parameters θ^0, hyperparameters β_t and $\eta_{t,l}$.
for $t = 0, 1, ..., T-1$ **do**
  Sample mini-batch data $\{\xi_{t,b}\}_{b=1,...,B}$;
  for Layers $l = 1, ..., L$ **do**
    Compute the stochastic gradient $g_l^t := \frac{1}{B}\sum_{b=1}^{B} \nabla_{\theta_l} \ell(\theta^t; \xi_{t,b})$;
    if $l = L$ (last layer) **then**
      $m_l^t = \beta_t m_l^{t-1} + (1-\beta_t) g_l^t$;
    else
      $m_l^t = g_l^t$ (record the gradient directly);
    end if
    $\theta_l^{t+1} = \theta_l^t - \eta_l \mathcal{C}(m_l^t)$ where $\mathcal{C}$ is the column-wise normalization;
  end for
end for
Output: Trained model θ^T.

- Start from plain SGD (zero state); add only what the diagnosis demands: (i) column-wise normalization on every weight matrix; (ii) last-layer momentum only.
- Memory: **SGD-like**: one EMA buffer for the last layer.
- Compute: one column-norm per matrix; negligible overhead.

正在讲话: yanliji;

会议概览

本次会议讨论了SGD和Nesterov加速器在大语言模型训练中的应用，分析了其性能差距的原因，并提出了针对性的修复方案和理论依据。

yanliji 指出EMA并非全局必需，通过对比各层方差发现，仅最后一层方差较大，对其应用EMA即可大幅降低噪声，这**打破了常规认知，相当于给模型做了个“减负”，把算力花在刀刃上。**

基于此，他提出仅对最后一层应用动量的猜想，并表示该结论在动量SGD的理论公式中能得到合理解释，**可见理论推导与实验数据形成了闭环，为优化策略提供了坚实依据。**

元宝会议助手 刚刚

yanliji 继续推导收敛边界公式，指出右侧的梯度方差项与层数相关，且受动量参数beta的递增函数影响，**这表明动量参数beta越大，方差项的放大效应越明显，对收敛稳定性的影响也越大。**

随后，他明确了动量参数beta的取值范围，将其限定在小于1减delta的区间内，**这其实是为理论推导划定了安全边界，确保动量机制在可控范围内生效。**

元宝会议助手 刚刚

yanliji 指出为降低收敛界，动量参数β应无限逼近1。但若某层梯度方差Σ趋近于零，为提升内存效率，可直接将该层β设为0，**这其实就是一种“抓大放小”的策略，用牺牲无关紧要层的计算资源来换取整体效率。**

基于此，yanliji 强调因最后一层Σ较大，必须保留动量机制，否则算法将失效，**可见最后一层是整个模型收敛的关键瓶颈，动量的设置完全由它说了算。**

我正在听，2分钟后生成总结... 立即总结

元宝会议助手
洞察讨论观点，总结纪要及待办

SCALE – Headline Results on LLaMA 60M – 1B

Model size Tokens	60M 1.4B	130M 2.6B	350M 7.8B	1B 20B
Adam	30.05 (0.35G)	23.13 (0.81G)	18.77 (2.21G)	15.79 (8.04G)
Adam (Stable-SPAM)	28.77 (0.35G)	22.20 (0.81G)	16.80 (2.21G)	13.30 (8.04G)
Muon	**28.86** (0.23G)	**22.20** (0.54G)	16.70 (1.47G)	13.67 (5.36G)
GaLore	34.58 (0.28G)	25.31 (0.61G)	19.37 (1.59G)	15.05 (4.76G)
Fira	30.34 (0.28G)	22.96 (0.61G)	16.82 (1.59G)	14.36 (4.76G)
SWAN	30.00 (0.25G)	22.83 (0.46G)	17.14 (1.00G)	–
APOLLO	30.94 (0.28G)	22.93 (0.61G)	16.75 (1.59G)	14.28 (4.76G)
APOLLO-Mini	31.85 (0.25G)	23.63 (0.46G)	17.11 (1.00G)	**13.48** (3.20G)
SCALE (ours)	30.81 (**0.15G**)	22.57 (**0.32G**)	**16.32** (**0.80G**)	**13.49** (**2.81G**)

Perplexity (lower is better) on C4; numbers in parentheses = optimizer-state memory.

- SCALE **matches or beats** Adam at $\sim 1/3$ to $1/2$ of its optimizer memory.
- Dominates GaLore / Fira / SWAN / APOLLO / Muon at every model size on memory *and* usually on perplexity.

会议详情 32:13
yanliji正在共享屏幕
演讲者布局 设置
元宝纪要
正在讲话: yanliji;
会议概览
本次会议讨论了SGD和Nesterov加速器在大语言模型训练中的应用，分析了其性能差距的原因，并提出了针对性的修复方案和理论依据。
yanliji 指出EMA并非全局必需，通过对比各层方差发现，仅最后一层方差较大，对其应用EMA即可大幅降低噪声，这打破了常规认知，相当于给模型做了个“减负”，把算力花在刀刃上。
基于此，他提出仅对最后一层应用动量的猜想，并表示该结论在动量SGD的理论公式中能得到合理解释，可见理论推导与实验数据形成了闭环，为优化策略提供了坚实依据。
元宝会议助手 刚刚
yanliji 继续推导收敛边界公式，指出右侧的梯度方差项与层数相关，且受动量参数beta的递增函数影响，这表明动量参数beta越大，方差项的放大效应越明显，对收敛稳定性的影响也越大。
随后，他明确了动量参数beta的取值范围，将其限定在小于1减delta的区间内，这其实是为理论推导划定了安全边界，确保动量机制在可控范围内生效。
元宝会议助手 刚刚
yanliji 指出为降低收敛界，动量参数β应无限逼近1。但若某层梯度方差Σ趋近于零，为提升内存效率，可直接将该层β设为0，这其实就是一种“抓大放小”的策略，用牺牲无关紧要层的计算资源来换取整体效率。
基于此，yanliji 强调因最后一层Σ较大，必须保留动量机制，否则算法将失效，可见最后一层是整个模型收敛的关键瓶颈，动量的设置完全由它说了算。
我正在听，2分钟后生成总结... 立即总结
元宝会议助手
洞察讨论观点，总结纪要及待办
批注
说点什么...
选择音频 开启视频 共享屏幕 成员(23) 邀请 聊天 录制 元宝纪要 应用 离开会议

SCALE – LLaMA-7B and the Pareto Frontier

7B (steps) Tokens	40K 5.2B	80K 10.5B	120K 15.7B	150K 19.7B
APOLLO (16.14G)	17.55	14.39	13.23	13.02
APOLLO-Mini (14.53G)	18.03	14.60	13.32	13.09
Muon (26.95G)	16.43	13.95	12.85	12.72
SCALE (13.74G)	17.99	14.57	12.86	**12.59**

LLaMA-7B perplexity on C4. SCALE achieves the best final perplexity at the smallest optimizer footprint.

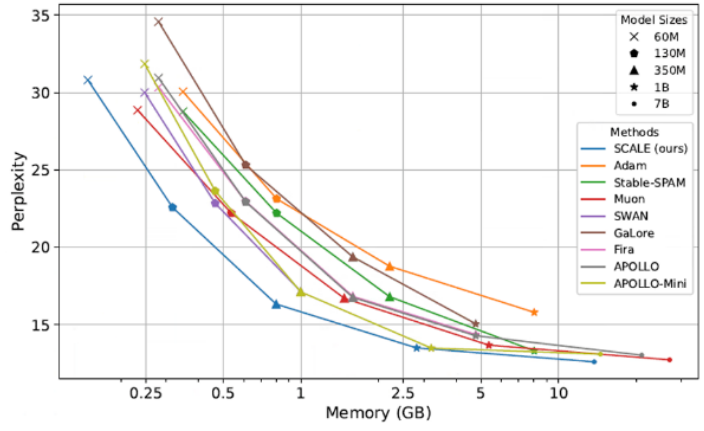

Memory–perplexity Pareto plot across optimizers; SCALE pushes the lower-left frontier.

- **Conclusion:** Building on classical SGD can obtain the new memory-efficient SOTA, as long as we respect gradient structure in LLM training.

会议详情 33:09
yanliji正在共享屏幕
演讲者布局 设置
元宝纪要
正在讲话: yanliji;
会议概览
本次会议讨论了SGD和Nesterov加速器在大语言模型训练中的应用，分析了SGD表现不佳的原因，并提出了通过梯度裁剪和简化算法来提升其性能及设计内存高效优化器的新方法。
yanliji 指出EMA并非全局必需，通过对比各层方差发现，仅最后一层方差较大，对其应用EMA即可大幅降低噪声，这打破了常规认知，相当于给模型做了个“减负”，把算力花在刀刃上。
基于此，他提出仅对最后一层应用动量的猜想，并表示该结论在动量SGD的理论公式中能得到合理解释，可见理论推导与实验数据形成了闭环，为优化策略提供了坚实依据。
元宝会议助手 刚刚
yanliji 继续推导收敛边界公式，指出右侧的梯度方差项与层数相关，且受动量参数beta的递增函数影响，这表明动量参数beta越大，方差项的放大效应越明显，对收敛稳定性的影响也越大。
随后，他明确了动量参数beta的取值范围，将其限定在小于1减delta的区间内，这其实是为理论推导划定了安全边界，确保动量机制在可控范围内生效。
元宝会议助手 刚刚
yanliji 指出为降低收敛界，动量参数β应无限逼近1。但若某层梯度方差Σ趋近于零，为提升内存效率，可直接将该层β设为0，这其实就是一种“抓大放小”的策略，用牺牲无关紧要层的计算资源来换取整体效率。
基于此，yanliji 强调因最后一层Σ较大，必须保留动量机制，否则算法将失效，可见最后一层是整个模型收敛的关键瓶颈，动量的设置完全由它说了算。
我正在听，2分钟后生成总结... 立即总结
元宝会议助手
洞察讨论观点，总结纪要及待办
批注
说点什么...
选择音频 开启视频 共享屏幕 成员(23) 邀请 聊天 录制 元宝纪要 应用 离开会议

Nesterov Acceleration

Nesterov (1983) Accelerated Gradient. For L-smooth convex f, take a lookahead step before each gradient evaluation:

$$y^t = x^t + \beta_t (x^t - x^{t-1}), \qquad x^{t+1} = y^t - \tfrac{1}{L}\nabla f(y^t).$$

- Achieves the accelerated rate $f(x^T) - f(x^\star) = \mathcal{O}(L/T^2)$ which is optimal among first-order methods on convex problems.
- One of the most widely-used ideas in *classical* optimization.

Question. *Can this classical acceleration help in deep-learning / LLM pre-training?*

The catch: deep-learning losses are non-convex, exhibit a river-valley geometry *(Wen et al., 2024)*: a long descending corridor with steep walls; naive lookahead may fail to work.

会议详情 34:25 yanliji正在共享屏幕 演讲者布局 设置
元宝纪要
正在讲话:
会议概览
本次会议讨论了SGD和Nesterov加速器在大语言模型训练中的应用，分析了SGD表现不佳的原因，并提出了通过梯度裁剪和简化算法来提升其性能及设计内存高效优化器的新方法。
元宝会议助手 刚刚
yanliji 指出为降低收敛界，动量参数β应无限逼近1。但若某层梯度方差Σ趋近于零，为提升内存效率，可直接将该层β设为0，这其实就是一种“抓大放小”的策略，用牺牲无关紧要层的计算资源来换取整体效率。
基于此，yanliji 强调因最后一层Σ较大，必须保留动量机制，否则算法将失效，可见最后一层是整个模型收敛的关键瓶颈，动量的设置完全由它说了算。
元宝会议助手 刚刚
yanliji 展示了新算法“scale”的测试结果，指出其性能逼近Adam且常优于其他内存高效算法，可见该算法在内存与性能间找到了极佳的平衡点。
针对高达1B参数量及27B模型的大规模测试表明，该算法内存占用极小，仅略逊于全参数训练，这直接证明了其在大模型训练场景下的实用价值。
元宝会议助手 刚刚
yanliji 通过对比图展示新算法在性能与内存占用上的综合优势，重申其基于SGD构建的新算法在7B模型训练中达到SOTA，这标志着该算法在内存与性能的平衡上实现了突破。
总结完第一部分后，yanliji 宣布会议进入第二部分，可见第一部分的理论推导与算法验证已圆满收官，接下来将开启全新的议题。
我正在听，2分钟后生成总结... 立即总结
元宝会议助手
洞察讨论观点，总结纪要及待办
批注
说点什么...
选择音频 开启视频 共享屏幕 成员(23) 邀请 聊天 录制 元宝纪要 应用 离开会议

Deep-Learning Loss Landscape – River Valley

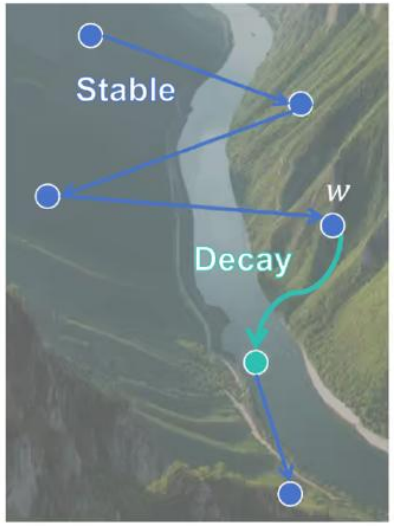

(a) River Valley Landscape

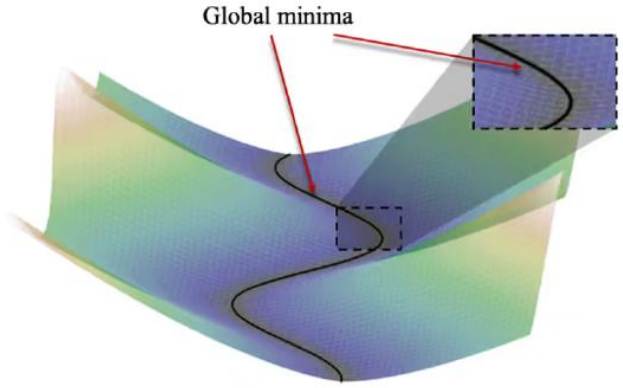

(b) Loss landscape of over-parameterized models

Figure: Deep-learning loss landscape described by (Left) Wen et al. (2024) and (Right) Liu et al. (2022). Training trajectory progresses above the minima, and converges to minima when learning rate decays.

会议详情 36:04
yanliji正在共享屏幕
演讲者布局 设置
正在讲话: yanliji;
元宝纪要
会议概览
本次会议探讨了SGD和Nesterov加速器在大语言模型训练中的应用，分析了SGD表现不佳的原因，并提出了通过梯度裁剪和简化算法使其表现更优的新方法。
元宝会议助手 刚刚
yanliji 展示了新算法“scale”的测试结果，指出其性能逼近Adam且常优于其他内存高效算法，**可见该算法在内存与性能间找到了极佳的平衡点。**
针对高达1B参数量及27B模型的大规模测试表明，该算法内存占用极小，仅略逊于全参数训练，**这直接证明了其在大模型训练场景下的实用价值。**
元宝会议助手 刚刚
yanliji 通过对比图展示新算法在性能与内存占用上的综合优势，重申其基于SGD构建的新算法在7B模型训练中达到SOTA，**这标志着该算法在内存与性能的平衡上实现了突破。**
总结完第一部分后，yanliji 宣布会议进入第二部分，**可见第一部分的理论推导与算法验证已圆满收官，接下来将开启全新的议题。**
元宝会议助手 刚刚
yanliji 引入1983年的Nesterov加速梯度法，指出其虽沿用梯度下降框架，但核心区别在于更新点并非当前位置，而是基于前瞻点。**这标志着议题从基础SGD正式转向更复杂的优化算法演进。**
随后，他详细拆解了算法公式，明确参数Beta控制前瞻步长，而当前与前一状态的差值则构成动量项。**可见该算法巧妙融合了前瞻预判与历史动量，旨在实现更高效的参数更新。**
我正在听，2分钟后生成总结... 立即总结
元宝会议助手
洞察讨论观点，总结纪要及待办
批注
说点什么...
选择音频 开启视频 共享屏幕 成员(24) 邀请 聊天 录制 元宝纪要 应用 离开会议

Part II – Making Lookahead Work

Why Naive Lookahead Fails, and Our Fix

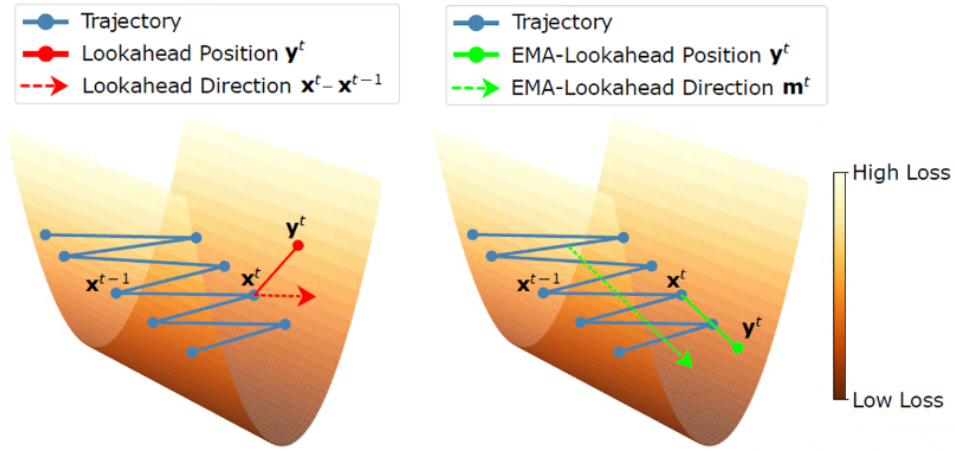

Classical lookahead (red): extrapolates the noisy one-step update $x^t - x^{t-1}$, overshoots, training diverges.

Our fix — EMA lookahead (green): replace the one-step delta with an EMA of past updates (the low-frequency trend).

$$m^t = \gamma\, m^{t-1} + (1-\gamma)\,(x^t - x^{t-1}), \qquad y^t = x^t + \beta\, m^t$$

批注

元宝纪要
正在讲话:
会议概览
本次会议探讨了SGD和Nesterov加速等经典优化算法在大语言模型训练中的有效性，并提出了针对性的改进方案。
小结
yanliji 通过对比图展示新算法在性能与内存占用上的综合优势，重申其基于SGD构建的新算法在7B模型训练中达到SOTA，这标志着该算法在内存与性能的平衡上实现了突破。
总结完第一部分后，yanliji 宣布会议进入第二部分，可见第一部分的理论推导与算法验证已圆满收官，接下来将开启全新的议题。
元宝会议助手 刚刚
yanliji 引入1983年的Nesterov加速梯度法，指出其虽沿用梯度下降框架，但核心区别在于更新点并非当前位置，而是基于前瞻点。这标志着议题从基础SGD正式转向更复杂的优化算法演进。
随后，他详细拆解了算法公式，明确参数Beta控制前瞻步长，而当前与前一状态的差值则构成动量项。可见该算法巧妙融合了前瞻预判与历史动量，旨在实现更高效的参数更新。
元宝会议助手 刚刚
yanliji 指出Nesterov加速法在凸优化中能实现平方级收敛，是经典优化利器，但在深度学习领域却因非凸性导致极不稳定，可见经典理论在非凸的复杂地形面前，直接套用往往会水土不服。
为解释该现象，他引入“河流山谷”地形猜想，指出损失在山谷中缓慢下降，而在两侧山丘上急剧上升，这其实就是用直观的地形特征，具象化解释了非凸优化的核心难点。
我正在听，2分钟后生成总结... 立即总结
元宝会议助手
洞察讨论观点，总结纪要及待办
说点什么...
选择音频 开启视频 共享屏幕 成员(24) 邀请 聊天 录制 元宝纪要 应用 离开会议

Can You Look Ahead? Lookahead Loss vs. β

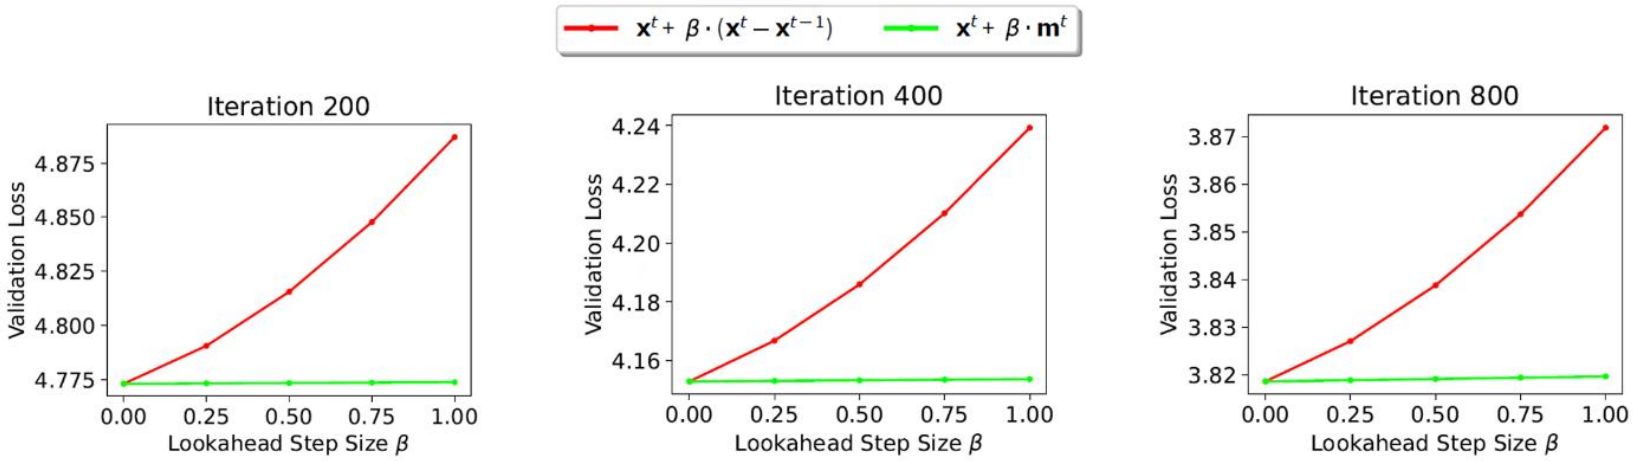

NanoGPT-124M: validation loss as we vary β along two lookahead directions at iterations 200/400/800.

- Classical $(x^t - x^{t-1})$: loss explodes at any nontrivial β.
- EMA (m^t): a wide, safe interval of β values, and lower validation loss.

会议详情 38:43 yanliji正在共享屏幕
演讲者布局 设置
元宝纪要
正在讲话:
会议概览
本次会议探讨了SGD和Nesterov加速等经典优化算法在大语言模型训练中的有效性，并提出了针对性的改进方案。
小结
基于前瞻点。这标志着议题从基础SGD正式转向更复杂的优化算法演进。
随后，他详细拆解了算法公式，明确参数Beta控制前瞻步长，而当前与前一状态的差值则构成动量项。可见该算法巧妙融合了前瞻预判与历史动量，旨在实现更高效的参数更新。
元宝会议助手 刚刚
yanliji 指出Nesterov加速法在凸优化中能实现平方级收敛，是经典优化利器，但在深度学习领域却因非凸性导致极不稳定，可见经典理论在非凸的复杂地形面前，直接套用往往会水土不服。
为解释该现象，他引入“河流山谷”地形猜想，指出损失在山谷中缓慢下降，而在两侧山丘上急剧上升，这其实就是用直观的地形特征，具象化解释了非凸优化的核心难点。
元宝会议助手 刚刚
yanliji 指出，在“河谷”地形下，Nesterov加速法因过度依赖前两次迭代点，导致算法在轨迹上跳变并落入更差位置，这直指传统优化器在复杂非凸地形中“刻舟求剑”的局限性。
基于此，他明确该方法在此场景下极不稳定，并提出修正方向：摒弃对前两次迭代的盲目信任，转而探索新的优化策略。可见，打破对历史路径的依赖，是解决当前算法失效的关键破局点。
我正在听，2分钟后生成总结... 立即总结
元宝会议助手
洞察讨论观点，总结纪要及待办
批注
说点什么...
选择音频 开启视频 共享屏幕 成员(24) 邀请 聊天 录制 元宝纪要 应用 离开会议

EMA-Nesterov – A Universal Wrapper

For any base optimizer $\mathcal{A}_t : \mathbb{R}^d \to \mathbb{R}^d$ (Adam, SOAP, Muon, ...):

Algorithm: EMA-Nesterov

$$\textbf{for } t = 0, \ldots, T-1:$$
$$x^{t+1} = \mathcal{A}_t\left(x^t + \beta_t\, m^t\right)$$
$$m^{t+1} = \gamma\, m^t + (1-\gamma)\left(x^{t+1} - x^t\right)$$
$$\textbf{end for}; \quad \textbf{return } x^T.$$

- $\gamma = 0$ recovers classical Nesterov lookahead.
- $\gamma \in (0, 1)$: low-pass filter on the update direction.
- Adds one extra buffer (m^t) and one extra cheap update per step.

正在讲话: yanliji;

会议概览

本次会议探讨了SGD和Nesterov加速等经典优化算法在大语言模型训练中的有效性，并提出了相应的改进方案。

小结

yanliji 指出，在“河谷”地形下，Nesterov加速法因过度依赖前两次迭代点，导致算法在轨迹上跳变并落入更差位置，**这直指传统优化器在复杂非凸地形中“刻舟求剑”的局限性。**

基于此，他明确该方法在此场景下极不稳定，并提出修正方向：摒弃对前两次迭代的盲目信任，转而探索新的优化策略。**可见，打破对历史路径的依赖，是解决当前算法失效的关键破局点。**

元宝会议助手 刚刚

yanliji 详细阐述了改进方案，通过引入指数平均（EMA）计算历史方向动量，并基于此进行前瞻计算，**这本质上是用平滑后的历史趋势替代单步跳跃，旨在解决原算法的不稳定性。**

随后，他将话题转向该改进方案在跨迭代场景下的潜在优势，准备进一步展开论证。**可见，他正试图从理论推导平滑过渡到实际效用的验证上。**

元宝会议助手 刚刚

yanliji 指出直接基于历史方向进行大步长前瞻会导致损失剧烈上升，证明该方向不可行，**这直接排除了一种直观但错误的优化路径。**

反之，采用EMA动量作为前瞻方向时，损失曲线保持平稳，且存在较宽的安全参数区间，**这表明新方案不仅有效，还具备极高的工程容错率。**

我正在听，2分钟后生成总结... 立即总结

元宝会议助手
洞察讨论观点，总结纪要及待办

Comparison to Existing Lookahead Algorithms

Prior Works	Lookahead Direction	Lookahead Frequency	Adaptivity
Nesterov's Accelerated Gradient (Nesterov, 1983)	$\mathbf{x}^t - \mathbf{x}^{t-1}$	1	✓
Pessimistic Lookahead (Zhang et al., 2019)	$-(\mathbf{x}^t - \mathbf{x}^{t-K})$	$1/K$	✗
NALA (Zuo et al., 2024)	$\mathbf{x}^t - \mathbf{x}^{t-K}$	$1/K$	✗
SNOO (Kallusky et al., 2025)	$\mathbf{x}^t - \mathbf{x}^{t-K}$ (Implicit)	$1/K$	✗
GPA (Defazio et al., 2025)	$\mathbf{x}^t - \mathbf{x}^{t-1}$ $+\mu \cdot (\mathbf{x}^t - \mathrm{EMA}(\{\mathbf{x}^r\}_{r=0}^{t-1}))$ (Implicit)	1	✗
EMA-Nesterov (Ours)	$\mathrm{EMA}(\{\mathbf{x}^r - \mathbf{x}^{r-1}\}_{r=1}^{t})$	1	✓

Table: Comparison between lookahead algorithms on the direction (short-horizon vs long-horizon) and frequency of lookahead. $K > 1$ is the number of optimizer updates for double-loop algorithms.

会议详情 41:06 yanliji正在共享屏幕
演讲者布局 设置
元宝纪要
正在讲话: yanliji;
会议概览
本次会议探讨了SGD和Nesterov加速等经典优化算法在大语言模型训练中的有效性，并提出了相应的改进方案。
小结
yanliji 指出，在“河谷”地形下，Nesterov加速法因过度依赖前两次迭代点，导致算法在轨迹上跳变并落入更差位置，这直指传统优化器在复杂非凸地形中“刻舟求剑”的局限性。
基于此，他明确该方法在此场景下极不稳定，并提出修正方向：摒弃对前两次迭代的盲目信任，转而探索新的优化策略。可见，打破对历史路径的依赖，是解决当前算法失效的关键破局点。
元宝会议助手 刚刚
yanliji 详细阐述了改进方案，通过引入指数平均（EMA）计算历史方向动量，并基于此进行前瞻计算，这本质上是用平滑后的历史趋势替代单步跳跃，旨在解决原算法的不稳定性。
随后，他将话题转向该改进方案在跨迭代场景下的潜在优势，准备进一步展开论证。可见，他正试图从理论推导平滑过渡到实际效用的验证上。
元宝会议助手 刚刚
yanliji 指出直接基于历史方向进行大步长前瞻会导致损失剧烈上升，证明该方向不可行，这直接排除了一种直观但错误的优化路径。
反之，采用EMA动量作为前瞻方向时，损失曲线保持平稳，且存在较宽的安全参数区间，这表明新方案不仅有效，还具备极高的工程容错率。
我正在听，2分钟后生成总结... 立即总结
元宝会议助手
洞察讨论观点，总结纪要及待办
批注
说点什么...
选择音频 开启视频 共享屏幕 成员(24) 邀请 聊天 录制 元宝纪要 应用 离开会议

Comparison to Existing Lookahead Algorithms

- Prior works are either
  (1) prone to short-horizon oscillation from $\mathbf{x}^t - \mathbf{x}^{t-1}$, or
  (2) perform long-horizon lookahead $\mathbf{x}^t - \mathbf{x}^{t-K}$ that does not adapt to the local trend of trajectory (see red below).

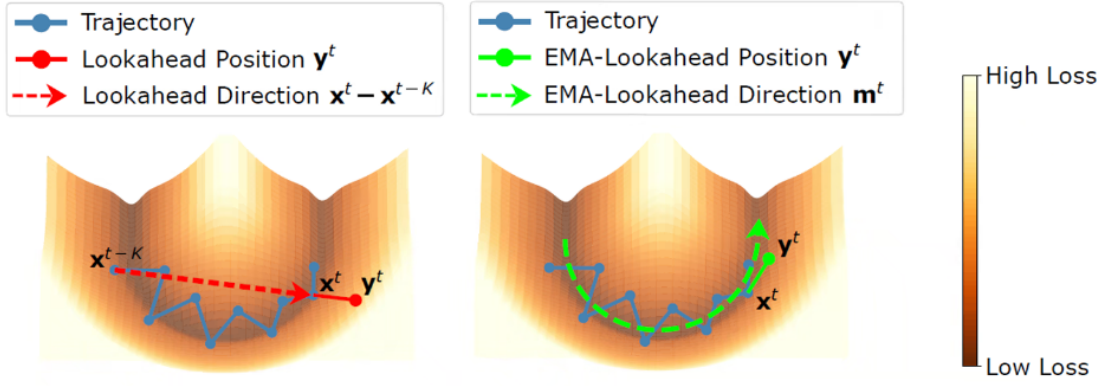

- In contrast, EMA-Nesterov's lookahead direction adapts to the recent trend.
- **Theoretical Gap:** Prior works do not provide accelerated convergence analysis.

会议详情 41:38
yanliji正在共享屏幕
演讲者布局 设置
正在讲话: yanliji;
元宝纪要
会议概览
本次会议探讨了SGD和Nesterov加速器在大语言模型训练中的应用，分析了其失效原因并提出了相应的修复算法。
小结
元宝会议助手 刚刚
yanliji 详细阐述了改进方案，通过引入指数平均（EMA）计算历史方向动量，并基于此进行前瞻计算，这本质上是用平滑后的历史趋势替代单步跳跃，旨在解决原算法的不稳定性。
随后，他将话题转向该改进方案在跨迭代场景下的潜在优势，准备进一步展开论证。可见，他正试图从理论推导平滑过渡到实际效用的验证上。
元宝会议助手 刚刚
yanliji 指出直接基于历史方向进行大步长前瞻会导致损失剧烈上升，证明该方向不可行，这直接排除了一种直观但错误的优化路径。
反之，采用EMA动量作为前瞻方向时，损失曲线保持平稳，且存在较宽的安全参数区间，这表明新方案不仅有效，还具备极高的工程容错率。
元宝会议助手 刚刚
yanliji 强调该方案并非新算法，而是可适配Adam、SGD等现有优化器的通用插件，通过前置动量计算来微调参数，这种“即插即用”的定位，极大降低了落地门槛，主打一个兼容并包。
随后，他指出该方案仅需在内存中额外维护一个动量矩阵，并对比了过往文献中不同的计算方向，可见在追求轻量化的同时，底层逻辑的差异才是决定效果的关键。
我正在听，2分钟后生成总结... 立即总结
元宝会议助手
洞察讨论观点，总结纪要及待办
批注
说点什么...
选择音频 开启视频 共享屏幕 成员(24) 邀请 聊天 录制 元宝纪要 应用 离开会议

Community Adaptation & Variants — NanoGPT Evolution Timeline

1. (The beginning) + Muon
2. + SOAP-Muon
3. + u/w floor / RowUpdateFloor
4. ... *many more techniques* ...
5. + EMA-Nesterov (EMA-Nesterov's contribution: -40 steps)
6. (Redundant techniques removed) – Circuit-Muon, – Contra-Muon, – Soft-Muon, – Aurora, – NorMuon-lite, ...
7. (Latest) + Tail-EMA (EMA-Nesterov's contribution: -95 steps)

批注

正在讲话:

会议概览

本次会议介绍了SGD和Nesterov加速器在大模型训练中的应用研究，旨在解决其性能瓶颈并提出改进算法。

小结

元宝会议助手 刚刚

yanliji 指出前人通过“向后看K步”来弥补“向前看一步”的不稳定性，但在复杂地形下依然失效，**这说明传统方法在应对复杂地形时，本质上还是治标不治本。**

随后，yanliji 强调其方案通过追踪曲线实现了更高稳定性，并辅以理论证明维持了原有收敛速度，**可见该方案不仅解决了稳定性痛点，还守住了算法效率的底线。**

元宝会议助手 刚刚

yanliji 展示了Yenma Struff在NanoGPT上的实验数据，指出将其应用于Meow、AdamW及Soap等主流优化器时，均能实现损失值的即时下降，**这表明该策略具备极强的通用性，能直接给各类优化器“打补丁”提效。**

随后，他将测试范围扩展至Llama系列大模型，并验证了不同批次大小下的表现，确认该策略在各项测试中均持续优于基准，**可见其不仅在小模型上有效，在更大规模模型上同样具备稳定的性能增益。**

元宝会议助手 刚刚

yanliji 指出Ema Net Strive最初在预训练算法测试中展现优势。在GPT模型测试中，该算法仅用2892步便达成目标，大幅领先其他方案，**这直接量化了其加速收敛的硬核实力。**

鉴于其作为通用“包装器”的特性，后续众多优化器均将其作为基准线进行性能对比，**可见该算法已成功确立行业新标杆，成为该领域的“试金石”。**

我正在听，2分钟后生成总结... 立即总结

元宝会议助手
洞察讨论观点，总结纪要及待办

Community Adaptation & Variants — The Impact of Auto-research in NanoGPT

NanoGPT Benchmark.

- Auto-research agents (e.g., Claude) are commonly used non-stop to help tuning the hyperparameters.

- Multiple rounds of auto-research are removing redundant techniques, e.g., Circuit-Muon, Contra-Muon, Aurora, NorMuon-lite, ... are removed in #44.
- EMA-Nesterov remains in the Track 3 top record PR#331 (as of 06/25) (2660 steps to 3.28 val. loss).

会议详情 45:55
yanliji正在共享屏幕
演讲者布局 设置
元宝纪要
正在讲话: yanliji;
会议概览
本次会议介绍了SGD和Nesterov加速器在大模型训练中的应用研究，旨在解决其性能瓶颈并提出改进算法。
小结
元宝会议助手 3分钟前
yanliji 指出前人通过“向后看K步”来弥补“向前看一步”的不稳定性，但在复杂地形下依然失效，这说明传统方法在应对复杂地形时，本质上还是治标不治本。
随后，yanliji 强调其方案通过追踪曲线实现了更高稳定性，并辅以理论证明维持了原有收敛速度，可见该方案不仅解决了稳定性痛点，还守住了算法效率的底线。
元宝会议助手 刚刚
yanliji 展示了Yenma Struff在NanoGPT上的实验数据，指出将其应用于Meow、AdamW及Soap等主流优化器时，均能实现损失值的即时下降，这表明该策略具备极强的通用性，能直接给各类优化器“打补丁”提效。
随后，他将测试范围扩展至Llama系列大模型，并验证了不同批次大小下的表现，确认该策略在各项测试中均持续优于基准，可见其不仅在小模型上有效，在更大规模模型上同样具备稳定的性能增益。
元宝会议助手 刚刚
yanliji 指出Ema Net Strive最初在预训练算法测试中展现优势。在GPT模型测试中，该算法仅用2892步便达成目标，大幅领先其他方案，这直接量化了其加速收敛的硬核实力。
鉴于其作为通用“包装器”的特性，后续众多优化器均将其作为基准线进行性能对比，可见该算法已成功确立行业新标杆，成为该领域的“试金石”。
我正在听，2分钟后生成总结... 立即总结
元宝会议助手
洞察讨论观点，总结纪要及待办
批注
说点什么...
选择音频 开启视频 共享屏幕 成员(25) 邀请 聊天 录制 元宝纪要 应用 离开会议

Community Adaptation & Variants — Parallax and Hyperball

Parallax (Zuo et al., 2026) with Hyperball (Wen et al., 2026) + EMA-Nesterov.

- Project the EMA lookahead direction to satisfy the Hyperball constraint.

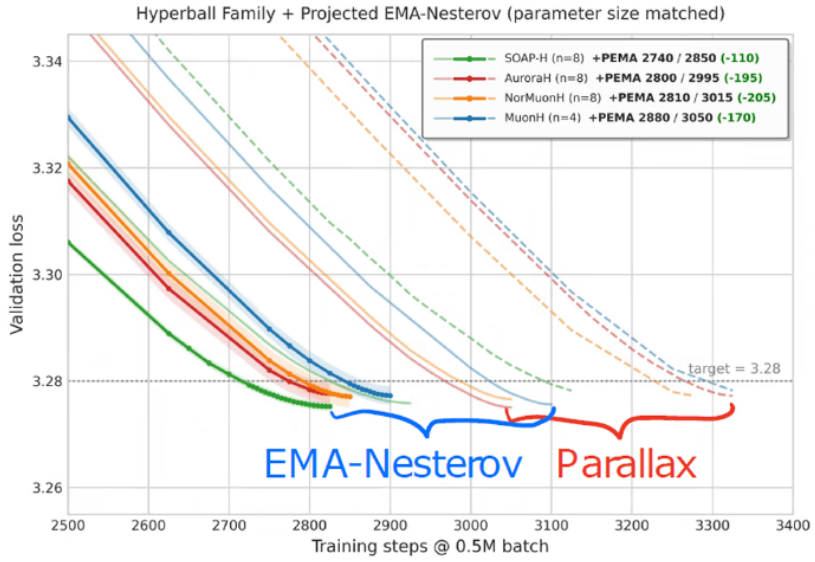

Figure: Credits to Min Li, Haoxiang Wang and Yifei Zuo. Results from Yifei's X post and GitHub.

会议详情 46:18
yanliji正在共享屏幕
演讲者布局 设置
元宝纪要
正在讲话:
会议概览
本次会议介绍了SGD和Nesterov加速器在大模型训练中的应用研究，旨在解决其性能瓶颈并提出改进算法。
小结
yanliji 展示了Yenma Struff在NanoGPT上的实验数据，指出将其应用于Meow、AdamW及Soap等主流优化器时，均能实现损失值的即时下降，这表明该策略具备极强的通用性，能直接给各类优化器“打补丁”提效。
随后，他将测试范围扩展至Llama系列大模型，并验证了不同批次大小下的表现，确认该策略在各项测试中均持续优于基准，可见其不仅在小模型上有效，在更大规模模型上同样具备稳定的性能增益。
元宝会议助手 刚刚
yanliji 指出Ema Net Strive最初在预训练算法测试中展现优势。在GPT模型测试中，该算法仅用2892步便达成目标，大幅领先其他方案，这直接量化了其加速收敛的硬核实力。
鉴于其作为通用“包装器”的特性，后续众多优化器均将其作为基准线进行性能对比，可见该算法已成功确立行业新标杆，成为该领域的“试金石”。
元宝会议助手 刚刚
yanliji 指出，后续研究者在引入Soap等技术并开展深度研究后，剔除了部分无效方案，而他们的Ema Nash Strive方法依然被保留，这说明该算法具备极强的鲁棒性，经得起同行反复验证与筛选。
基于此，yanliji 强调该方法在优化器性能评估中的贡献度显著提升，其核心价值在对比中愈发凸显，可见，在激烈的算法迭代中，能活下来的才是真正具备核心竞争力的技术。
我正在听，2分钟后生成总结... 立即总结
元宝会议助手
洞察讨论观点，总结纪要及待办
批注
说点什么...
选择音频 开启视频 共享屏幕 成员(25) 邀请 聊天 录制 元宝纪要 应用 离开会议

Conclusions

A common message across two threads:

Classical optimization ideas, treated with the right respect for the structure of LLM, are very useful for modern LLM training.

- **Part I (SGD).** A two-property diagnosis of the SGD/Adam gap ⇒ SCALE: stateless column-norm + last-layer momentum, ∼ 35–45% of Adam's memory, matches or beats Adam from 60M to 7B.
- **Part II (Nesterov).** EMA-stabilized lookahead ⇒ EMA-Nesterov: keeps the classical accelerated convex rate, consistently accelerates Adam / SOAP / Muon / NorMuon on NanoGPT, improves performance on large batch LLaMA and large model up to LLaMA-1B.

批注

正在讲话:

会议概览

本次会议介绍了SGD和Nesterov加速器在大模型训练中的应用研究，旨在解决其性能瓶颈并提出改进算法。

小结

yanliji 展示了Yenma Struff在NanoGPT上的实验数据，指出将其应用于Meow、AdamW及Soap等主流优化器时，均能实现损失值的即时下降，**这表明该策略具备极强的通用性，能直接给各类优化器“打补丁”提效。**

随后，他将测试范围扩展至Llama系列大模型，并验证了不同批次大小下的表现，确认该策略在各项测试中均持续优于基准，**可见其不仅在小模型上有效，在更大规模模型上同样具备稳定的性能增益。**

元宝会议助手 刚刚

yanliji 指出Ema Net Strive最初在预训练算法测试中展现优势。在GPT模型测试中，该算法仅用2892步便达成目标，大幅领先其他方案，**这直接量化了其加速收敛的硬核实力。**

鉴于其作为通用“包装器”的特性，后续众多优化器均将其作为基准线进行性能对比，**可见该算法已成功确立行业新标杆，成为该领域的“试金石”。**

元宝会议助手 刚刚

yanliji 指出，后续研究者在引入Soap等技术并开展深度研究后，剔除了部分无效方案，而他们的Ema Nash Strive方法依然被保留，**这说明该算法具备极强的鲁棒性，经得起同行反复验证与筛选。**

基于此，yanliji 强调该方法在优化器性能评估中的贡献度显著提升，其核心价值在对比中愈发凸显，**可见，在激烈的算法迭代中，能活下来的才是真正具备核心竞争力的技术。**

我正在听，2分钟后生成总结... 立即总结

元宝会议助手 ⇌
洞察讨论观点，总结纪要及待办

Open Directions

- **Theory for clipped SGD on LLM gradients.** A convergence theory matching the empirical SCALE /SGD-LL story.
- **EMA-Nesterov as a generic optimizer wrapper.** More extensive experiments needed to validate the effects of EMA-Nesterov for larger-scale training (Part II).
- **Beyond pre-training.** Do the models trained via different optimizers have different effect on the downstream tasks? (Perplexity/Eval loss is not the only evaluator)
- **Other "classical" ideas to revisit:** variance reduction, second-order methods, primal-dual splitting; Will some of those be helpful in foundation model training?

会议详情 47:28 yanliji正在共享屏幕
演讲者布局 设置
元宝纪要
正在讲话: yanliji;
会议概览
本次会议介绍了SGD和Nesterov加速器在大模型训练中的应用研究，旨在解决其性能瓶颈并提出改进算法。
小结
元宝会议助手 刚刚
yanliji 指出Ema Net Strive最初在预训练算法测试中展现优势。在GPT模型测试中，该算法仅用2892步便达成目标，大幅领先其他方案，这直接量化了其加速收敛的硬核实力。
鉴于其作为通用"包装器"的特性，后续众多优化器均将其作为基准线进行性能对比，可见该算法已成功确立行业新标杆，成为该领域的"试金石"。
元宝会议助手 刚刚
yanliji 指出，后续研究者在引入Soap等技术并开展深度研究后，剔除了部分无效方案，而他们的Ema Nash Strive方法依然被保留，这说明该算法具备极强的鲁棒性，经得起同行反复验证与筛选。
基于此，yanliji 强调该方法在优化器性能评估中的贡献度显著提升，其核心价值在对比中愈发凸显，可见，在激烈的算法迭代中，能活下来的才是真正具备核心竞争力的技术。
元宝会议助手 刚刚
yanliji 指出其算法近期登顶某组件榜单，并提及Parallax工作。该工作改进注意力机制时引入其算法，性能提升显著，这波"强强联手"直接秀出了算法的硬核实力。
数据显示，结合该算法后训练步数大幅减少。基于此，yanliji 总结该算法是适用于多种架构的通用插件，相当于给各种模型打了一针"加速剂"，普适性极强。
我正在听，2分钟后生成总结... 立即总结
元宝会议助手
洞察讨论观点，总结纪要及待办
批注
说点什么...
选择音频 开启视频 共享屏幕 成员(25) 邀请 聊天 录制 元宝纪要 应用 离开会议